Fine-tuning e Análise do Aprendizado de Modelos de Linguagem Navegando por Labirintos em ASCII

Anderson N. Silva[1]

[1]Departamento Acadêmico de Informática (DAINF) –
Universidade Tecnológica Federal do Paraná (UTFPR)
Av. Sete de Setembro, 3165 – 80230-901 – Curitiba – PR – Brasil

andersonnogueira@alunos.utfpr.edu.br

Abstract. *10 lines and must be in the first page of the paper.*

Resumo. *Este meta-artigo descreve o estilo a ser usado na confecção de artigos e*

1. Introdução

A resolução de labirintos é uma tarefa clássica que demanda raciocínio espacial, planejamento e adaptação a ambientes estruturados. Tradicionalmente, algoritmos simbólicos e métodos baseados em busca foram empregados para solucionar esse tipo de problema. No entanto, com o avanço dos Modelos de Linguagem de Grande Escala (*Large Language Models* - LLMs), surge a oportunidade de investigar como essas arquiteturas, originalmente projetadas para linguagem natural, podem ser adaptadas para tarefas que exigem compreensão espacial e manipulação de representações simbólicas.

Apesar do sucesso dos LLMs em tarefas linguísticas, ainda há lacunas no entendimento de como esses modelos internalizam e representam informações espaciais, especialmente após processos de especialização como o *fine-tuning*. O caráter de "caixa-preta" dos LLMs dificulta a análise dos mecanismos internos responsáveis pelo aprendizado e pela tomada de decisão, tornando essencial o uso de técnicas de explicabilidade para investigar as transformações ocorridas nas redes neurais durante o treinamento para tarefas específicas.

Neste contexto, este trabalho propõe investigar como LLMs abertos, com até 8 bilhões de parâmetros, aprendem a resolver labirintos representados em ASCII por meio de diferentes estratégias de *fine-tuning*. O objetivo central é analisar as mudanças nas ativações internas das redes neurais associadas ao aprendizado da tarefa, utilizando a biblioteca LLM-MRI [Costa et al. 2024] para visualizar e comparar as representações neuronais antes e depois do processo de aprendizagem. A análise busca identificar padrões emergentes, alterações estruturais e possíveis mecanismos de raciocínio espacial desenvolvidos pelos modelos.

Os principais objetivos específicos deste estudo são: (i) aplicar diferentes estratégias de *fine-tuning* em LLMs abertos para a tarefa de resolução de labirintos em ASCII; (ii) avaliar o desempenho dos modelos antes e após o ajuste; (iii) utilizar a LLM-MRI para visualizar e comparar as ativações neuronais; (iv) investigar padrões emergentes e alterações nas representações internas; e (v) discutir as implicações dos resultados para o entendimento do raciocínio e da representação de tarefas específicas em LLMs.

Ao abordar essas questões, este trabalho visa contribuir tanto para o avanço prático das técnicas de especialização de LLMs quanto para o aprofundamento teórico sobre os processos de representação e raciocínio em redes neurais profundas. O foco está no entendimento dos mecanismos de raciocínio espacial em LLMs, avaliando desempenho e interpretabilidade dos modelos em tarefas estruturadas de navegabilidade em labirintos textuais.

O restante desta proposta está organizado da seguinte forma: a Seção 2 evidencia os trabalhos relacionados e os fundamentos teóricos necessários para o entendimento do tema; a Seção 3 detalha a metodologia que será adotada para o desenvolvimento do trabalho, incluindo a preparação dos dados, seleção de modelos, estratégias de ajuste e análise das ativações neurais; por fim, a Seção 4 apresenta resultados e evidências preliminares obtidas até o momento, além de discutir perspectivas para o aprofundamento do estudo.

2. Fundamentos e Trabalhos Relacionados

Esta seção reúne os fundamentos teóricos e os trabalhos relacionados que sustentam o desenvolvimento deste estudo, abordando os conceitos essenciais sobre labirintos, LLMs, estratégias de fine-tuning e métodos de explicabilidade.

2.1. Labirintos e Raciocínio Espacial

Labirintos são estruturas clássicas amplamente utilizadas para investigar processos de raciocínio espacial, planejamento e navegação, especialmente no contexto de agentes artificiais [Vartak 2023]. Conceitualmente, um labirinto pode ser definido como um ambiente composto por caminhos interconectados, obstáculos e pontos de decisão, cujo objetivo é encontrar uma rota eficiente entre um ponto de entrada e um de saída. A resolução de labirintos demanda a construção de representações espaciais internas, identificação de padrões e adaptação de estratégias a partir da estrutura do ambiente, como [Sadik et al. 2010] aborda comparando diferentes técnicas baseadas em teoria dos grafos.

Neste trabalho, labirintos em ASCII são empregados como um domínio controlado para testar a capacidade de modelos de linguagem em desenvolver representações espaciais e estratégias de navegação a partir de entradas exclusivamente textuais. Essa escolha permite investigar, com o apoio de técnicas de explicabilidade, se os modelos são capazes de realizar raciocínio estrutural coerente ou se apenas se baseiam em padrões estatísticos superficiais.

2.2. LLMs - Large Language Models

Os LLMs representam um marco no avanço do Processamento de Linguagem Natural (PLN), resultado de uma trajetória que abrange: modelos estatísticos, como n-gram; passando por modelos baseados em *word embeddings*, como Word2Vec [Mikolov et al. 2013]; *Recurrent Neural Networks* (RNNs) e *Long Short-Term Memory* (LSTM) [Hochreiter and Schmidhuber 1997] e, mais recentemente, arquiteturas baseadas em *transformers* [Jurafsky and Martin 2025].

2.2.1. Arquitetura Transformer e Mecanismo de Atenção

O desenvolvimento dos LLMs está diretamente ligado à evolução dos transformers, introduzidos por [Vaswani et al. 2023], que revolucionaram o campo ao permitir a modelagem eficiente de dependências contextuais de longo alcance, por meio de mecanismos de atenção. Sua arquitetura é composta por blocos de *encoder* e *decoder*, que podem ser utilizados separadamente ou em conjunto, conforme a tarefa. A figura 1 ilustra a arquitetura básica de um transformer, destacando seus componentes principais.

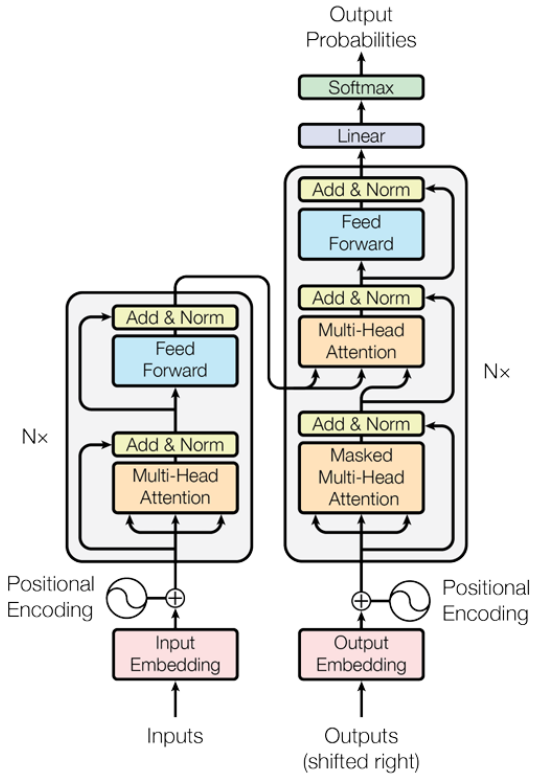


Figure 1. Arquitetura básica de um transformer, com blocos de encoder e decoder [Vaswani et al. 2023].

Modelos recentes, como o BERT [Devlin et al. 2019], utilizam apenas o encoder, sendo eficazes em tarefas de compreensão textual, enquanto modelos GPT [Yenduri et al. 2023] utilizam apenas o decoder, focando na geração de texto. Arquiteturas encoder-decoder, como o T5 [Raffel et al. 2023], são empregadas em tarefas de tradução e sumarização [Tunstall et al. 2022].

2.2.2. Pré-treinamento e fine-tuning

O treinamento dos LLMs ocorre em duas etapas principais: pré-treinamento e ajuste fino (*fine-tuning*). No pré-treinamento, os modelos são expostos a grandes volumes de dados textuais não rotulados, aprendendo representações linguísticas gerais por meio de tarefas como predição de palavras mascaradas ou geração de texto [Tunstall et al. 2022]. Essa etapa é fundamental para fornecer aos modelos capacidades de compreensão e geração de

linguagem [Zhao et al. 2025]. O *fine-tuning*, abordado em seção específica deste trabalho (2.3), permite especializar o modelo para tarefas ou domínios específicos.

2.2.3. Modelos Atuais

LLMs modernos, como GPT-3 [Brown et al. 2020], GPT-4 [OpenAI et al. 2024], PaLM [Chowdhery et al. 2022] e outros, possuem bilhões de parâmetros e apresentam habilidades emergentes, incluindo raciocínio, compreensão semântica e adaptação a múltiplos contextos. No entanto, estudos e bibliografias recentes evidenciam limitações importantes desses modelos, como a propensão a respostas não factuais, vieses sociais e dificuldades em tarefas que exigem raciocínio profundo ou conhecimento de mundo [Chang and Bergen 2023, Summerfield 2025].

Além dos LLMs tradicionais, surgiram variantes especializadas, como os Large Reasoning Models (LRMs) que incorporam mecanismos de raciocínio explícito [Lynch 2025], e os Multimodal Vision Language Models (VLMs) [Li et al. 2025], que integram texto e imagens para tarefas multimodais. Essas alternativas buscam superar limitações dos LLMs convencionais e ampliar o espectro de aplicações dos modelos de linguagem.

2.3. Fine-tuning de LLMs

O *fine-tuning* é uma etapa fundamental para adaptar LLMs a tarefas específicas, permitindo que modelos previamente treinados em grandes volumes de dados textuais sejam ajustados para contextos e domínios particulares. Neste trabalho, destacam-se duas estratégias principais: o **Supervised Fine-Tuning (SFT)** e o **Group Relative Policy Optimization (GRPO)**.

O **SFT** consiste no ajuste supervisionado do modelo utilizando conjuntos de dados rotulados, nos quais o modelo aprende a associar instruções ou entradas a saídas desejadas. Essa técnica é amplamente empregada para especializar LLMs em tarefas como classificação, tradução e, no contexto deste estudo, navegação em labirintos ASCII. O processo envolve a construção de um dataset de pares (instrução, saída) e o treinamento supervisionado para minimizar o erro entre a resposta do modelo e a resposta esperada [Zhang et al. 2024]. O SFT é considerado eficiente, pois permite adaptar rapidamente o modelo a novos domínios sem a necessidade de re-treinamento completo.

Já o **GRPO** é uma técnica baseada em otimização de políticas relativas a grupos, utilizada para aprimorar o desempenho do modelo considerando preferências coletivas de múltiplos usuários ou agentes. No GRPO, o modelo é ajustado para maximizar a satisfação de critérios definidos por grupos, promovendo respostas mais alinhadas a contextos colaborativos ou multiusuário [Dao and Vu 2025]. Essa abordagem é especialmente relevante em cenários onde a diversidade de preferências e estratégias é importante para o sucesso da tarefa.

Essas estratégias são relevantes para o presente estudo, pois permitem investigar como diferentes métodos de ajuste podem impactar o desempenho dos LLMs em tarefas de raciocínio espacial.

2.4. Explicabilidade em LLMs

Apesar do alto desempenho, LLMs são frequentemente criticados por seu caráter de "caixa-preta", dificultando o entendimento sobre como tomam decisões e levantando preocupações éticas e de confiança [Zhao et al. 2023, Cambria et al. 2024, Luo and Specia 2024]. A opacidade desses modelos pode resultar em respostas inesperadas, enviesadas ou até mesmo em alucinações, o que reforça a necessidade de técnicas de explicabilidade (*explainability*) para tornar seus mecanismos internos mais transparentes.

A explicabilidade em LLMs pode ser abordada sob diferentes perspectivas. Do ponto de vista do usuário final, explicações claras e acessíveis são essenciais para promover confiança e permitir o uso responsável dos modelos em aplicações sensíveis, como saúde, educação e finanças. Para pesquisadores e desenvolvedores, a explicabilidade atua como ferramenta de diagnóstico, facilitando a identificação de vieses, falhas e oportunidades de aprimoramento dos modelos [Zhao et al. 2023, Luo and Specia 2024].

As principais técnicas de explicabilidade para LLMs incluem métodos de atribuição de importância a tokens (feature attribution), análise de camadas internas, visualização de mecanismos de atenção e explicações baseadas em exemplos. Recentemente, abordagens baseadas em prompts e cadeias de raciocínio (*chain-of-thought* [Wei et al. 2023]) também têm sido exploradas para tornar o processo de decisão dos modelos mais interpretável [Zhao et al. 2023]. No entanto, o aumento da escala e da complexidade dos LLMs impõe desafios adicionais, tornando a geração de explicações confiáveis e compreensíveis uma tarefa ainda em aberto.

Além disso, a literatura destaca a importância de desenvolver métricas e benchmarks específicos para avaliar a qualidade das explicações geradas, bem como de promover a integração entre avanços em LLMs e técnicas de XAI (Explainable AI) [Cambria et al. 2024]. O avanço conjunto dessas áreas é fundamental para garantir o uso ético, seguro e transparente dos modelos de linguagem em aplicações reais.

2.4.1. LLM-MRI

A biblioteca LLM-MRI (*Large Language Model - Magnetic Resonance Imaging*) é uma ferramenta desenvolvida para facilitar a análise de padrões de ativação em LLMs baseados em *transformer*. Conforme apresentado por [Costa et al. 2024], a LLM-MRI permite coletar, organizar e projetar em dimensões reduzidas os vetores de ativação gerados pelos modelos ao processarem diferentes entradas. Técnicas de redução de dimensionalidade possibilitam visualizar como as ativações neuronais se distribuem, facilitando a identificação de padrões e a análise das mudanças provocadas por diferentes estratégias de fine-tuning.

No contexto deste trabalho, a LLM-MRI é empregada para investigar como LLMs se adaptam à tarefa de navegação em labirintos ASCII e como as estruturas internas dos modelos evoluem durante o processo de aprendizagem, contribuindo para a análise da interpretabilidade e do raciocínio espacial dos modelos.

2.5. Trabalhos Relacionados

Esta seção apresenta a revisão de literatura sobre o tema deste trabalho, com foco em LLMs, fine-tunning e explicabilidade.

2.5.1. Labirintos como Domínio Estrutural para Raciocínio Espacial

A investigação do raciocínio espacial em modelos de linguagem tem utilizado labirintos como um domínio estruturado e simbólico, capaz de revelar limitações e padrões de generalização dos modelos. O benchmark introduzido por [Zhou et al. 2024], avalia a suscetibilidade dos LLMs a se apoiarem em atalhos (*shortcuts*) superficiais, ou correlações onde não há relação de causa-efeito, que afetam a robustez dos modelos em tarefas de classificação de texto.

Em outra abordagem, [Hsu et al. 2025] propuseram o framework Deep Schema Grounding (DSG), que utiliza LLMs para extrair e estruturar representações simbólicas (schemas) do conceito de labirinto, promovendo um raciocínio mais alinhado à cognição humana ao combinar essas abstrações com modelos multimodais. Essas contribuições reforçam a relevância dos labirintos textuais como ambiente de análise para o comportamento de LLMs em tarefas que exigem planejamento, abstração e robustez interpretativa.

2.5.2. Raciocínio Espacial em LLMs

O raciocínio espacial em LLMs tem sido explorado por diferentes abordagens, buscando adaptar esses modelos para tarefas que exigem compreensão e manipulação de ambientes estruturados.

O AlphaMaze [Dao and Vu 2025] propõe um processo em duas etapas: inicialmente, o modelo é ajustado via Supervised Fine-Tuning (SFT) para aprender comandos de movimentação em labirintos textuais; em seguida, utiliza-se o Group Relative Policy Optimization (GRPO) para aprimorar o raciocínio e a autocorreção. O MazeBench é empregado para avaliar o desempenho dos modelos em diferentes níveis de dificuldade, evidenciando ganhos após o GRPO.

Em paralelo, [Wang et al. 2024] questionam a vantagem de modelos multimodais em tarefas espaciais, mostrando que LLMs baseados apenas em texto podem superar alternativas multimodais, o que reforça a relevância de investigar estratégias específicas para LLMs textuais. Em contextos tridimensionais, [Zhang et al. 2025] identificam limitações dos LLMs, enquanto [Cheng et al. 2024] propõem integrar módulos de representação de regiões e informações de profundidade para melhorar a compreensão espacial.

Outras abordagens, como o Chain-of-Symbol (COS) Prompting [Hu et al. 2024], convertem descrições em linguagem natural para representações simbólicas intermediárias, otimizando o planejamento espacial e reduzindo o uso de tokens. Já o Visualization of Thought (VoT) [Wu et al. 2024] estimula a geração de representações visuais em ASCII art, inspirando-se na cognição humana para melhorar o acompanhamento de estados e o planejamento de ações. Embora o VoT apresente avanços em determinados cenários, sua eficácia depende das habilidades emergentes dos modelos e da qualidade dos prompts, sendo limitado em tarefas mais complexas ou com modelos menos robustos.

Ainda, mesmo com avanços recentes, variantes como os LRMs, que incorporam mecanismos explícitos de raciocínio, como cadeias de pensamento (*Chain-of-Thought* [Wei et al. 2023]) e auto-reflexão, ainda enfrentam desafios em tarefas de alta complexidade, apresentando limitações na generalização e fenômenos como raciocínio redundante

ou ineficiente [Shojaee et al. 2025].

Por fim, no contexto deste trabalho, o raciocínio espacial é central, pois o objetivo é investigar como LLMs podem ser ajustados e analisados para resolver labirintos representados em ASCII. As abordagens discutidas na literatura fornecem subsídios para a escolha de técnicas de fine-tuning e avaliação, além de motivar o uso de ferramentas de explicabilidade para compreender como as representações internas dos modelos evoluem ao longo do treinamento.

2.5.3. Fine-tuning de LLMs para Tarefas Específicas

O fine-tuning de LLMs para tarefas específicas é um tema amplamente investigado, com diferentes estratégias sendo propostas para aprimorar a adaptação dos modelos. Por exemplo, [Jiang et al. 2024] demonstra que o uso de SFT pode melhorar tanto as representações internas quanto a capacidade de generalização, mesmo em modelos visuais, evidenciando a importância do ajuste direcionado para tarefas de raciocínio espacial.

Além disso, [Hsieh et al. 2023] propõem a utilização de *rationales* gerados por LLMs como supervisão adicional em um cenário multitarefa, combinando rótulos e explicações para enriquecer o sinal de treinamento. Essa abordagem, baseada em Chain-of-Thought prompting [Wei et al. 2023], permite que modelos menores alcancem desempenho superior a LLMs maiores, mesmo com menos dados, ao tornar o processo de ajuste mais eficiente e interpretável. No contexto deste trabalho, a integração de racionalizações se mostra relevante para aprimorar a eficiência e a interpretabilidade dos modelos.

2.5.4. Explicabilidade em LLMs

A explicabilidade em LLMs é um campo em expansão, com abordagens que buscam tornar os modelos mais transparentes e compreensíveis. A biblioteca LLM-MRI [Costa et al. 2024] destaca-se por permitir a análise e visualização das ativações neuronais, facilitando a interpretação de como os modelos se adaptam a tarefas específicas.

Complementarmente, [Wu et al. 2025] propõem o conceito de Usable XAI, que enfatiza a aplicação prática das explicações para diagnóstico e aprimoramento dos modelos. Entre as estratégias discutidas estão métodos de atribuição, análise das ativações internas e explicações baseadas em exemplos, todas relevantes para entender a evolução das representações internas durante o fine-tuning. A integração dessas abordagens contribui para identificar limitações, corrigir vieses e aprimorar o desempenho dos modelos em tarefas que exigem alto grau de interpretabilidade.

3. Metodologia

Esta seção apresenta o planejamento metodológico para investigar como LLMs abertos podem aprender a resolver labirintos em ASCII, analisando as mudanças nas ativações internas das redes neurais após diferentes estratégias de *fine-tuning*. O objetivo é detalhar os procedimentos que serão adotados, de modo a garantir a replicabilidade do estudo, incluindo a preparação dos dados, o ajuste dos modelos, a avaliação de desempenho e a análise das ativações neuronais.

3.1. Preparação dos Dados

Será utilizado um conjunto de dados composto por labirintos representados em ASCII, gerados automaticamente para garantir diversidade de estruturas e níveis de dificuldade. Existe a possibilidade de empregar os mesmos datasets de treinamento utilizados no trabalho AlphaMaze, uma vez que esses dados e configurações estão disponíveis publicamente. No entanto, ainda não está definido se as configurações dos labirintos e a forma de representação textual seguirão exatamente o padrão do AlphaMaze ou se será desenvolvida uma nova abordagem de geração e representação dos labirintos. Cada instância do conjunto conterá a representação textual do labirinto, a posição inicial e final, e a sequência de comandos esperada para a solução. Os dados serão divididos em conjuntos de treinamento, validação e teste, assegurando que os labirintos do conjunto de teste não sejam vistos durante o treinamento.

3.2. Modelos e Estratégias de Fine-tuning

Serão selecionados LLMs abertos com até 8 bilhões de parâmetros, compatíveis com a biblioteca LLM-MRI. Existe também a possibilidade de utilizar os mesmos modelos empregados no AlphaMaze, visto que esses modelos estão disponíveis publicamente, o que facilitaria a comparação de resultados. O processo de especialização dos modelos será realizado por meio de diferentes estratégias de *fine-tuning*, conforme discutido na literatura:

- **Supervised Fine-Tuning (SFT)**: ajuste supervisionado utilizando exemplos de labirintos e suas soluções.
- **Group Relative Policy Optimization (GRPO)**: ajuste baseado em preferências coletivas, visando aprimorar o raciocínio e a autocorreção dos modelos.

Cada modelo será treinado separadamente em cada estratégia, utilizando os mesmos dados de entrada para garantir comparabilidade.

3.3. Avaliação de Desempenho

O desempenho dos modelos será avaliado antes e após o *fine-tuning*, utilizando métricas objetivas como taxa de sucesso na resolução dos labirintos, número médio de passos até a solução e precisão na geração dos comandos. Para garantir rigor na avaliação, os resultados serão comparados com abordagens tradicionais e com benchmarks da literatura, como o MazeBench.

3.4. Análise das Ativações Neuronais

A análise das ativações internas será conduzida com o auxílio da biblioteca LLM-MRI [Costa et al. 2024]. Para cada modelo e estratégia de ajuste, serão coletados os vetores de ativação das camadas intermediárias ao processar diferentes labirintos. Uma redução de dimensionalidade será aplicada para visualizar e comparar as distribuições das ativações antes e depois do treinamento. O objetivo será identificar padrões emergentes, alterações estruturais e possíveis mecanismos de raciocínio espacial desenvolvidos pelos modelos.

3.5. Hipóteses do Estudo

Este estudo parte das seguintes hipóteses principais:

H1: Estratégias distintas de *fine-tuning*, como SFT e GRPO, produzirão padrões diferentes de ativação interna, refletindo abordagens variadas de raciocínio espacial e representação da tarefa.

H2: A análise das ativações neuronais, por meio da LLM-MRI, permitirá identificar alterações estruturais e padrões emergentes associados ao aprendizado da tarefa, contribuindo para a compreensão dos mecanismos internos dos modelos.

3.6. Discussão e Interpretação dos Resultados

Os resultados quantitativos e qualitativos serão analisados de forma integrada, buscando compreender como as diferentes estratégias de *fine-tuning* influenciam tanto o desempenho quanto as representações internas dos LLMs. A discussão considerará limitações, possíveis vieses e implicações para o desenvolvimento de modelos mais interpretáveis e eficientes em tarefas que exigem raciocínio espacial.

4. Resultados Preliminares e Discussão

References

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., and Amodei, D. (2020). Language Models are Few-Shot Learners.

Cambria, E., Malandri, L., Mercorio, F., Nobani, N., and Seveso, A. (2024). XAI meets LLMs: A Survey of the Relation between Explainable AI and Large Language Models.

Chang, T. A. and Bergen, B. K. (2023). Language Model Behavior: A Comprehensive Survey.

Cheng, A.-C., Yin, H., Fu, Y., Guo, Q., Yang, R., Kautz, J., Wang, X., and Liu, S. (2024). SpatialRGPT: Grounded Spatial Reasoning in Vision Language Models.

Chowdhery, A., Narang, S., Devlin, J., Bosma, M., Mishra, G., Roberts, A., Barham, P., Chung, H. W., Sutton, C., Gehrmann, S., Schuh, P., Shi, K., Tsvyashchenko, S., Maynez, J., Rao, A., Barnes, P., Tay, Y., Shazeer, N., Prabhakaran, V., Reif, E., Du, N., Hutchinson, B., Pope, R., Bradbury, J., Austin, J., Isard, M., Gur-Ari, G., Yin, P., Duke, T., Levskaya, A., Ghemawat, S., Dev, S., Michalewski, H., Garcia, X., Misra, V., Robinson, K., Fedus, L., Zhou, D., Ippolito, D., Luan, D., Lim, H., Zoph, B., Spiridonov, A., Sepassi, R., Dohan, D., Agrawal, S., Omernick, M., Dai, A. M., Pillai, T. S., Pellat, M., Lewkowycz, A., Moreira, E., Child, R., Polozov, O., Lee, K., Zhou, Z., Wang, X., Saeta, B., Diaz, M., Firat, O., Catasta, M., Wei, J., Meier-Hellstern, K., Eck, D., Dean, J., Petrov, S., and Fiedel, N. (2022). PaLM: Scaling Language Modeling with Pathways.

Costa, L., Figênio, M., Santanchè, A., and Gomes-Jr, L. (2024). LLM-MRI Python module: a brain scanner for LLMs. In *Anais Estendidos do XXXIX Simpósio Brasileiro de Bancos de Dados*, pages 125–130, Porto Alegre, RS, Brasil. SBC.

Dao, A. and Vu, D. B. (2025). AlphaMaze: Enhancing Large Language Models' Spatial Intelligence via GRPO.

Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.

Hochreiter, S. and Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8):1735–1780.

Hsieh, C.-Y., Li, C.-L., Yeh, C.-K., Nakhost, H., Fujii, Y., Ratner, A., Krishna, R., Lee, C.-Y., and Pfister, T. (2023). Distilling Step-by-Step! Outperforming Larger Language Models with Less Training Data and Smaller Model Sizes.

Hsu, J., Mao, J., Tenenbaum, J. B., Goodman, N. D., and Wu, J. (2025). What Makes a Maze Look Like a Maze?

Hu, H., Lu, H., Zhang, H., Song, Y.-Z., Lam, W., and Zhang, Y. (2024). Chain-of-Symbol Prompting Elicits Planning in Large Langauge Models.

Jiang, X., Ge, Y., Ge, Y., Shi, D., Yuan, C., and Shan, Y. (2024). Supervised Fine-tuning in turn Improves Visual Foundation Models.

Jurafsky, D. and Martin, J. H. (2025). *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. Draft, Stanford, CA, 3rd edition. Draft of January 12, 2025. Copyright ©2024. All rights reserved.

Li, Z., Wu, X., Du, H., Liu, F., Nghiem, H., and Shi, G. (2025). A Survey of State of the Art Large Vision Language Models: Alignment, Benchmark, Evaluations and Challenges.

Luo, H. and Specia, L. (2024). From Understanding to Utilization: A Survey on Explainability for Large Language Models.

Lynch, G. (2025). Current and Future Techniques in the Training of Large Reasoning Models. TechRxiv. Preprint.

Mikolov, T., Sutskever, I., Chen, K., Corrado, G., and Dean, J. (2013). Distributed Representations of Words and Phrases and their Compositionality.

OpenAI, Achiam, J., Adler, S., Agarwal, S., Ahmad, L., Akkaya, I., Aleman, F. L., Almeida, D., Altenschmidt, J., Altman, S., Anadkat, S., Avila, R., Babuschkin, I., Balaji, S., Balcom, V., Baltescu, P., Bao, H., Bavarian, M., Belgum, J., Bello, I., Berdine, J., Bernadett-Shapiro, G., Berner, C., Bogdonoff, L., Boiko, O., Boyd, M., Brakman, A.-L., Brockman, G., Brooks, T., Brundage, M., Button, K., Cai, T., Campbell, R., Cann, A., Carey, B., Carlson, C., Carmichael, R., Chan, B., Chang, C., Chantzis, F., Chen, D., Chen, S., Chen, R., Chen, J., Chen, M., Chess, B., Cho, C., Chu, C., Chung, H. W., Cummings, D., Currier, J., Dai, Y., Decareaux, C., Degry, T., Deutsch, N., Deville, D., Dhar, A., Dohan, D., Dowling, S., Dunning, S., Ecoffet, A., Eleti, A., Eloundou, T., Farhi, D., Fedus, L., Felix, N., Fishman, S. P., Forte, J., Fulford, I., Gao, L., Georges, E., Gibson, C., Goel, V., Gogineni, T., Goh, G., Gontijo-Lopes, R., Gordon, J., Grafstein, M., Gray, S., Greene, R., Gross, J., Gu, S. S., Guo, Y., Hallacy, C., Han, J., Harris, J., He, Y., Heaton, M., Heidecke, J., Hesse, C., Hickey, A., Hickey, W., Hoeschele, P., Houghton, B., Hsu, K., Hu, S., Hu, X., Huizinga, J., Jain, S., Jain, S., Jang, J., Jiang, A., Jiang, R., Jin, H., Jin, D., Jomoto, S., Jonn, B., Jun, H., Kaftan, T., Łukasz Kaiser, Kamali, A., Kanitscheider, I., Keskar, N. S., Khan, T., Kilpatrick,

L., Kim, J. W., Kim, C., Kim, Y., Kirchner, J. H., Kiros, J., Knight, M., Kokotajlo, D., Łukasz Kondraciuk, Kondrich, A., Konstantinidis, A., Kosic, K., Krueger, G., Kuo, V., Lampe, M., Lan, I., Lee, T., Leike, J., Leung, J., Levy, D., Li, C. M., Lim, R., Lin, M., Lin, S., Litwin, M., Lopez, T., Lowe, R., Lue, P., Makanju, A., Malfacini, K., Manning, S., Markov, T., Markovski, Y., Martin, B., Mayer, K., Mayne, A., McGrew, B., McKinney, S. M., McLeavey, C., McMillan, P., McNeil, J., Medina, D., Mehta, A., Menick, J., Metz, L., Mishchenko, A., Mishkin, P., Monaco, V., Morikawa, E., Mossing, D., Mu, T., Murati, M., Murk, O., Mély, D., Nair, A., Nakano, R., Nayak, R., Neelakantan, A., Ngo, R., Noh, H., Ouyang, L., O'Keefe, C., Pachocki, J., Paino, A., Palermo, J., Pantuliano, A., Parascandolo, G., Parish, J., Parparita, E., Passos, A., Pavlov, M., Peng, A., Perelman, A., de Avila Belbute Peres, F., Petrov, M., de Oliveira Pinto, H. P., Michael, Pokorny, Pokrass, M., Pong, V. H., Powell, T., Power, A., Power, B., Proehl, E., Puri, R., Radford, A., Rae, J., Ramesh, A., Raymond, C., Real, F., Rimbach, K., Ross, C., Rotsted, B., Roussez, H., Ryder, N., Saltarelli, M., Sanders, T., Santurkar, S., Sastry, G., Schmidt, H., Schnurr, D., Schulman, J., Selsam, D., Sheppard, K., Sherbakov, T., Shieh, J., Shoker, S., Shyam, P., Sidor, S., Sigler, E., Simens, M., Sitkin, J., Slama, K., Sohl, I., Sokolowsky, B., Song, Y., Staudacher, N., Such, F. P., Summers, N., Sutskever, I., Tang, J., Tezak, N., Thompson, M. B., Tillet, P., Tootoonchian, A., Tseng, E., Tuggle, P., Turley, N., Tworek, J., Uribe, J. F. C., Vallone, A., Vijayvergiya, A., Voss, C., Wainwright, C., Wang, J. J., Wang, A., Wang, B., Ward, J., Wei, J., Weinmann, C., Welihinda, A., Welinder, P., Weng, J., Weng, L., Wiethoff, M., Willner, D., Winter, C., Wolrich, S., Wong, H., Workman, L., Wu, S., Wu, J., Wu, M., Xiao, K., Xu, T., Yoo, S., Yu, K., Yuan, Q., Zaremba, W., Zellers, R., Zhang, C., Zhang, M., Zhao, S., Zheng, T., Zhuang, J., Zhuk, W., and Zoph, B. (2024). GPT-4 Technical Report.

Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., and Liu, P. J. (2023). Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer.

Sadik, A. M., Dhali, M. A., Farid, H. M., Rashid, T. U., and Syeed, A. (2010). A Comprehensive and Comparative Study of Maze-Solving Techniques by Implementing Graph Theory. In *2010 International Conference on Artificial Intelligence and Computational Intelligence*, volume 1, pages 52–56.

Shojaee, P., Mirzadeh, I., Alizadeh, K., Horton, M., Bengio, S., and Farajtabar, M. (2025). The Illusion of Thinking: Understanding the Strengths and Limitations of Reasoning Models via the Lens of Problem Complexity.

Summerfield, C. (2025). *These Strange New Minds: How AI Learned to Talk and What It Means*. Viking, Penguin Random House LLC, New York, NY, 1 edition. First published in Great Britain by Viking (Penguin Random House Ltd., London). Cover design by David Litman.

Tunstall, L., von Werra, L., and Wolf, T. (2022). *Natural Language Processing with Transformers*. O'Reilly Media, Inc., Sebastopol, CA, USA, 1 edition. First Edition, February 2022.

Vartak, V. U. (2023). Maze Solver Robot using A* algorithm. Master's thesis, California State University, Northridge, Northridge. Committee Members: Saba Janamian, MD Sahabul Alam.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. u., and Polosukhin, I. (2023). Attention is All you Need. In Guyon, I., Luxburg, U. V., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., and Garnett, R., editors, *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc.

Wang, J., Ming, Y., Shi, Z., Vineet, V., Wang, X., Li, Y., and Joshi, N. (2024). Is A Picture Worth A Thousand Words? Delving Into Spatial Reasoning for Vision Language Models.

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., and Zhou, D. (2023). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models.

Wu, W., Mao, S., Zhang, Y., Xia, Y., Dong, L., Cui, L., and Wei, F. (2024). Mind's Eye of LLMs: Visualization-of-Thought Elicits Spatial Reasoning in Large Language Models.

Wu, X., Zhao, H., Zhu, Y., Shi, Y., Yang, F., Hu, L., Liu, T., Zhai, X., Yao, W., Li, J., Du, M., and Liu, N. (2025). Usable XAI: 10 Strategies Towards Exploiting Explainability in the LLM Era.

Yenduri, G., M, R., G, C. S., Y, S., Srivastava, G., Maddikunta, P. K. R., G, D. R., Jhaveri, R. H., B, P., Wang, W., Vasilakos, A. V., and Gadekallu, T. R. (2023). Generative Pre-trained Transformer: A Comprehensive Review on Enabling Technologies, Potential Applications, Emerging Challenges, and Future Directions.

Zhang, S., Dong, L., Li, X., Zhang, S., Sun, X., Wang, S., Li, J., Hu, R., Zhang, T., Wu, F., and Wang, G. (2024). Instruction Tuning for Large Language Models: A Survey.

Zhang, W., Peng, R., Gao, C., Fang, J., Zeng, X., Li, K., Wang, Z., Cui, J., Wang, X., Chen, X., and Li, Y. (2025). The Point, the Vision and the Text: Does Point Cloud Boost Spatial Reasoning of Large Language Models?

Zhao, H., Chen, H., Yang, F., Liu, N., Deng, H., Cai, H., Wang, S., Yin, D., and Du, M. (2023). Explainability for Large Language Models: A Survey.

Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z., Du, Y., Yang, C., Chen, Y., Chen, Z., Jiang, J., Ren, R., Li, Y., Tang, X., Liu, Z., Liu, P., Nie, J.-Y., and Wen, J.-R. (2025). A Survey of Large Language Models.

Zhou, Y., Tang, R., Yao, Z., and Zhu, Z. (2024). Navigating the Shortcut Maze: A Comprehensive Analysis of Shortcut Learning in Text Classification by Language Models.