UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ

ANDERSON NOGUEIRA SILVA

ANÁLISE DO APRENDIZADO POR FINE-TUNNING DE MODELOS DE LINGUAGEM NAVEGANDO POR LABIRINTOS EM ASCII

CURITIBA

2025

ANDERSON NOGUEIRA SILVA

ANÁLISE DO APRENDIZADO POR FINE-TUNNING DE MODELOS DE LINGUAGEM NAVEGANDO POR LABIRINTOS EM ASCII

Analysis of Learning via Fine-Tuning of Language Models Navigating ASCII Mazes

Trabalho de Conclusão de Curso de Graduação apresentado como requisito para obtenção do título de Bacharel em Engenharia de Computação do Curso de Bacharelado em Engenharia de Computação da Universidade Tecnológica Federal do Paraná.

Orientador: Prof. Dr. Luiz Celso Gomes Junior

CURITIBA

2025

4.0 Internacional

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es). Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

ANDERSON NOGUEIRA SILVA

ANÁLISE DO APRENDIZADO POR FINE-TUNNING DE MODELOS DE LINGUAGEM NAVEGANDO POR LABIRINTOS EM ASCII

Trabalho de Conclusão de Curso de Graduação apresentado como requisito para obtenção do título de Bacharel em Engenharia de Computação do Curso de Bacharelado em Engenharia de Computação da Universidade Tecnológica Federal do Paraná.

Data de aprovação: 05/dezembro/2025

André Santanchè
Doutorado
Universidade Estadual de Campinas - UNICAMP

Cristiano Sampaio Pinheiro
Graduação
Universidade Estadual de Campinas - UNICAMP

CURITIBA

2025

RESUMO

Este estudo investiga os efeitos do *fine-tuning* em modelos de linguagem encarregados de navegar por labirintos em ASCII por meio da utilização da biblioteca LLM-MRI. Ao analisar os grafos de ativações gerados a partir dos embeddings dos modelos, avaliamos as mudanças estruturais utilizando diversas métricas de grafos com inferência de distribuições por amostragem estatística. Nossos achados indicam alterações sutis, porém não significativas, nas estruturas dos grafos após o *fine-tuning*, sugerindo que, embora o *fine-tuning* influencie o processamento de informações, essas mudanças não são drasticamente refletidas nas métricas analisadas. O estudo destaca a importância de considerar diferentes níveis de abstração dentro dos modelos para compreender plenamente o impacto do *fine-tuning*. Trabalhos futuros recomendados incluem a exploração de prompts diversos, uso de *embbeddings* que capturem a resolução da tarefa e os efeitos de várias técnicas de *fine-tuning* e arquiteturas de modelos nas estruturas dos grafos de ativações.

Palavras-chave: labirinto; ascii; large language models; fine-tunning; llm mri.

ABSTRACT

This study investigates the effects of fine-tuning on language models tasked with navigating ASCII mazes through the use of the LLM-MRI library. By analyzing the activation graphs generated from the models' embeddings, we assess structural changes using various graph metrics with distribution inference via statistical sampling. Our findings indicate subtle, yet not significant, alterations in the graph structures after fine-tuning, suggesting that, although fine-tuning influences information processing, these changes are not drastically reflected in the analyzed metrics. The study highlights the importance of considering different levels of abstraction within the models to fully understand the impact of fine-tuning. Recommended future work includes exploring diverse prompts, using embbeddings that capture task resolution, and examining the effects of various fine-tuning techniques and model architectures on activation graph structures.

Keywords: maze; ascii; large language models; fine-tunning; llm mri.

LISTA DE FIGURAS

Figura 1 – Arquitetura básica de um transformer, com blocos de encoder e decoder (VASWANI *et al.*, 2023). **11**
Figura 2 – Média cumulativa do Grau Médio ($\bar{k}$). **23**
Figura 3 – KDE do Grau Médio ($\bar{k}$). **24**
Figura 4 – Média cumulativa da Densidade (ρ). **24**
Figura 5 – KDE da Densidade (ρ). **25**
Figura 6 – Média cumulativa da Assortatividade (r). **26**
Figura 7 – KDE da Assortatividade (r). **26**
Figura 8 – Média cumulativa do Diâmetro (D). **27**
Figura 9 – KDE do Diâmetro (D). **27**
Figura 10 – Média cumulativa do Comprimento Médio do Caminho ($\bar{L}$). **28**
Figura 11 – KDE do Comprimento Médio do Caminho ($\bar{L}$). **28**
Figura 12 – Média cumulativa da Densidade (ρ) **29**
Figura 13 – KDE da Densidade (ρ) **30**
Figura 14 – Média cumulativa da Assortatividade (r). **30**
Figura 15 – KDE da Assortatividade (r). **31**

LISTA DE TABELAS

Tabela 1 – Informações dos modelos utilizados nos experimentos. **18**

Tabela 2 – p-values ANOVA e Testes t pareados (Base vs SFT, Base vs GRPO) – Todas as camadas. **31**

Tabela 3 – p-values ANOVA e Testes t pareados (Base vs SFT, Base vs GRPO) – Últimas 5 camadas. **31**

SUMÁRIO

1 INTRODUÇÃO 8

LinkbordercolorLinkcolor1.1 Considerações iniciais 8

LinkbordercolorLinkcolor1.2 Objetivos 8

1.2.1 Objetivo geral 8

1.2.2 Objetivos específicos 8

LinkbordercolorLinkcolor1.3 Justificativa 9

LinkbordercolorLinkcolor1.4 Estrutura do Trabalho 9

2 REFERENCIAL TEÓRICO 10

LinkbordercolorLinkcolor2.1 Labirintos e Raciocínio Espacial 10

LinkbordercolorLinkcolor2.2 LLMs - Large Language Models 10

2.2.1 Arquitetura Transformer e Mecanismo de Atenção 10

LinkbordercolorLinkcolor2.3 Fine-tuning de LLMs 11

LinkbordercolorLinkcolor2.4 Explicabilidade em LLMs 12

2.4.1 LLM-MRI 13

3 TRABALHOS RELACIONADOS 14

LinkbordercolorLinkcolor3.1 Labirintos como Domínio Estrutural para Raciocínio Espacial 14

LinkbordercolorLinkcolor3.2 Raciocínio Espacial em LLMs 14

LinkbordercolorLinkcolor3.3 Fine-tuning de LLMs para Tarefas Específicas 15

LinkbordercolorLinkcolor3.4 Explicabilidade em LLMs 15

4 METODOLOGIA 17

LinkbordercolorLinkcolor4.1 Dados 17

LinkbordercolorLinkcolor4.2 Modelos e Estratégias de Fine-tuning 18

LinkbordercolorLinkcolor4.3 Procedimentos de Processamento, Métricas e Estatística 19

4.3.1 Pré-processamento e Validação Inicial 19

4.3.2 Métricas de Ciências das Redes 19

4.3.3 Amostragem para Inferência de Distribuições 20

4.3.4 Significância Estatística 21

LinkbordercolorLinkcolor4.4 Máquina e Recursos Computacionais 21
4.4.1 Tempos de Execução 21
4.4.2 Configuração da máquina 22
LinkbordercolorLinkcolor4.5 Síntese Metodológica e Hipóteses Iniciais . . 22
5 RESULTADOS 23
LinkbordercolorLinkcolor5.1 Resultados Considerando Todas as Camadas de Ativações 23
5.1.1 Grau Médio ($\bar{k}$) 23
5.1.2 Densidade (ρ) 24
5.1.3 Assortatividade (r) 25
5.1.4 Diâmetro (D) 25
5.1.5 Comprimento Médio do Caminho ($\bar{L}$) 26
LinkbordercolorLinkcolor5.2 Resultados Considerando Apenas as Últimas Cinco Camadas de Ativações 27
5.2.1 Densidade (ρ) 29
5.2.2 Assortatividade (r) 29
LinkbordercolorLinkcolor5.3 Testes de Significância Estatística 30
6 CONCLUSÃO 33
LinkbordercolorLinkcolor6.1 Análise dos Prompts Utilizados 33
LinkbordercolorLinkcolor6.2 Resultados das Métricas dos Grafos de Ativações Recorrentes 33
LinkbordercolorLinkcolor6.3 Limitações do Estudo 34
LinkbordercolorLinkcolor6.4 Trabalhos Futuros 34
LinkbordercolorLinkcolor6.5 Conclusão 35
REFERÊNCIAS 36

1 INTRODUÇÃO

Neste capítulo, são apresentadas as considerações iniciais do trabalho, os objetivos gerais e específicos da pesquisa, a justificativa para a escolha do tema e a estrutura do trabalho.

1.1 Considerações iniciais

A resolução de labirintos é uma tarefa clássica que demanda raciocínio espacial, planejamento e adaptação a ambientes estruturados. Tradicionalmente, algoritmos simbólicos e métodos baseados em busca foram empregados para solucionar esse tipo de problema. No entanto, com o avanço dos Modelos de Linguagem de Grande Escala (*Large Language Models* - LLMs), surge a oportunidade de investigar como essas arquiteturas, originalmente projetadas para linguagem natural, podem ser adaptadas para tarefas que exigem compreensão espacial e manipulação de representações simbólicas.

Apesar do sucesso dos LLMs em tarefas linguísticas, ainda há lacunas no entendimento de como esses modelos internalizam e representam informações espaciais, especialmente após processos de especialização como o *fine-tuning*. O caráter de "caixa-preta" dos LLMs dificulta a análise dos mecanismos internos responsáveis pelo aprendizado e pela tomada de decisão, tornando essencial o uso de técnicas de explicabilidade para investigar as transformações ocorridas nas redes neurais durante o treinamento para tarefas específicas.

1.2 Objetivos

Neste contexto, este trabalho propõe-se a investigar como LLMs abertos, neste estudo com 1,5 bilhões de parâmetros, aprendem a resolver labirintos representados em ASCII por meio de diferentes estratégias de *fine-tuning*.

1.2.1 Objetivo geral

O objetivo central é analisar as mudanças nas ativações internas das redes neurais associadas ao aprendizado da tarefa, utilizando a biblioteca LLM-MRI (COSTA *et al.*, 2024) para visualizar e comparar as representações neuronais antes e depois do processo de aprendizagem além de avaliar métricas de redes complexas aplicadas aos grafos de ativações gerados.

1.2.2 Objetivos específicos

Dentre os objetivos específicos deste estudo, destacam-se:

- Verificar como diferentes estratégias de *fine-tuning* refletem nas ativações internas dos modelos;
- Analisar as estruturas dos grafos de ativações recorrentes gerados a partir dos embeddings dos modelos;
- Avaliar métricas de grafos para identificar padrões emergentes e alterações nas representações internas;
- Discutir as implicações dos resultados para o entendimento do raciocínio espacial em LLMs.

1.3 Justificativa

Ao abordar essas questões, este trabalho visa contribuir tanto para o avanço no entendimento prático das técnicas de especialização de LLMs quanto para o aprofundamento teórico sobre os processos de representação e raciocínio em redes neurais profundas. O foco está no entendimento dos mecanismos de raciocínio espacial em LLMs, avaliando desempenho e interpretabilidade dos modelos em tarefas estruturadas de navegabilidade em labirintos textuais.

Como parte dos resultados obtidos, observou-se que as diferenças nas ativações internas dos modelos após o *fine-tuning* foram menos discrepantes do que inicialmente esperado. Embora o *fine-tuning* influencie o processamento de informações nos modelos, as mudanças estruturais nos grafos de ativações não foram significativamente refletidas nas métricas analisadas. Essas observações são discutidas em detalhes na seção de discussão, onde são exploradas possíveis razões para esses achados e suas implicações para futuras pesquisas na área.

1.4 Estrutura do Trabalho

O restante desta proposta está organizado da seguinte forma: o Capítulo 2 detalha os fundamentos teóricos necessários para o entendimento do tema; o Capítulo 3 evidencia os trabalhos relacionados relevantes; o Capítulo 4 detalha a metodologia que foi adotada para o desenvolvimento deste estudo, incluindo a preparação dos dados, seleção de modelos, estratégias de ajuste e análise das métricas sobre os grafos de ativações neurais; os resultados obtidos são discutidos no Capítulo 5; por fim, o Capítulo 6 apresenta as conclusões, limitações e perspectivas para o aprofundamento do estudo.

2 REFERENCIAL TEÓRICO

Esta seção reúne os fundamentos teóricos que sustentam o desenvolvimento deste estudo, abordando os conceitos essenciais sobre labirintos, LLMs, estratégias de fine-tuning e métodos de explicabilidade.

2.1 Labirintos e Raciocínio Espacial

Labirintos são estruturas clássicas amplamente utilizadas para investigar processos de raciocínio espacial, planejamento e navegação, especialmente no contexto de agentes artificiais (VARTAK, 2023). Conceitualmente, um labirinto pode ser definido como um ambiente composto por caminhos interconectados, obstáculos e pontos de decisão, cujo objetivo é encontrar uma rota eficiente entre um ponto de entrada e um de saída. A resolução de labirintos demanda a construção de representações espaciais internas, identificação de padrões e adaptação de estratégias a partir da estrutura do ambiente, como (SADIK *et al.*, 2010) aborda comparando diferentes técnicas baseadas em teoria dos grafos.

Neste trabalho, labirintos em ASCII são empregados como um domínio controlado para testar a capacidade de modelos de linguagem em desenvolver representações espaciais e estratégias de navegação a partir de entradas exclusivamente textuais. Essa escolha permite investigar, com o apoio de técnicas de explicabilidade, se os modelos são capazes de realizar raciocínio estrutural coerente ou se apenas se baseiam em padrões estatísticos superficiais.

2.2 LLMs - Large Language Models

Os LLMs representam um marco no avanço do Processamento de Linguagem Natural (PLN), resultado de uma trajetória que abrange: modelos estatísticos, como n-gram; passando por modelos baseados em *word embeddings*, como Word2Vec (MIKOLOV *et al.*, 2013); *Recurrent Neural Networks* (RNNs) e *Long Short-Term Memory* (LSTM) (HOCHREITER; SCHMIDHUBER, 1997) e, mais recentemente, arquiteturas baseadas em *transformers* (JURAFSKY; MARTIN, 2025).

2.2.1 Arquitetura Transformer e Mecanismo de Atenção

O desenvolvimento dos LLMs está diretamente ligado à evolução dos transformers, introduzidos por (VASWANI *et al.*, 2023), que revolucionaram o campo ao permitir a modelagem eficiente de dependências contextuais de longo alcance, por meio de mecanismos de atenção. Sua arquitetura é composta por blocos de *encoder* e *decoder*, que podem ser utilizados se-

paradamente ou em conjunto, conforme a tarefa. A figura 1 ilustra a arquitetura básica de um transformer, destacando seus componentes principais.

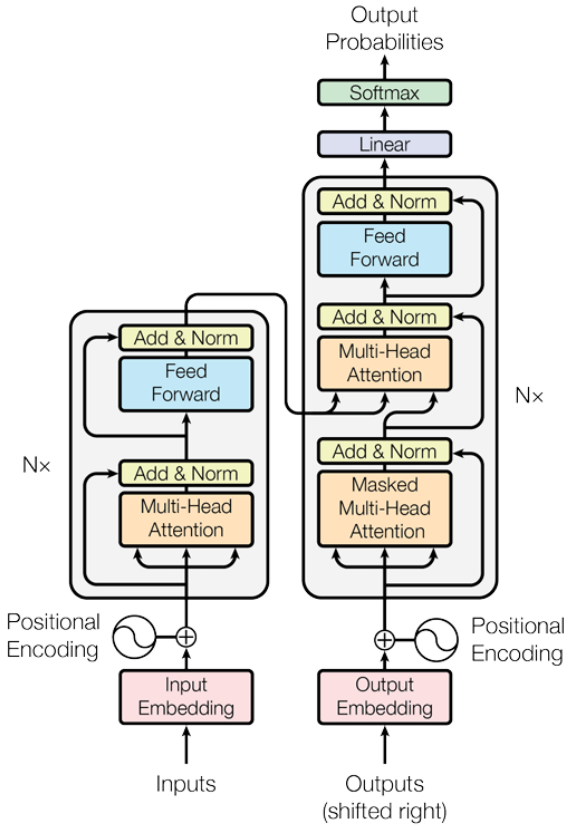


Figura 1 – Arquitetura básica de um transformer, com blocos de encoder e decoder (VASWANI *et al.*, 2023).

Modelos recentes, como o BERT (DEVLIN *et al.*, 2019), utilizam apenas o encoder, sendo eficazes em tarefas de compreensão textual, enquanto modelos GPT (YENDURI *et al.*, 2023) utilizam apenas o decoder, focando na geração de texto. Arquiteturas encoder-decoder, como o T5 (RAFFEL *et al.*, 2023), são empregadas em tarefas de tradução e sumarização (TUNSTALL; WERRA; WOLF, 2022).

2.3 Fine-tuning de LLMs

O *fine-tuning* é uma etapa fundamental para adaptar LLMs a tarefas específicas, permitindo que modelos previamente treinados em grandes volumes de dados textuais sejam ajustados para contextos e domínios particulares. Neste trabalho, destacam-se duas estratégias principais: o **Supervised Fine-Tuning (SFT)** e o **Group Relative Policy Optimization (GRPO)**.

O **SFT** consiste no ajuste supervisionado do modelo utilizando conjuntos de dados rotulados, nos quais o modelo aprende a associar instruções ou entradas a saídas desejadas. Essa técnica é amplamente empregada para especializar LLMs em tarefas como classificação, tradução e, no contexto deste estudo, navegação em labirintos ASCII. O processo envolve a

construção de um dataset de pares (instrução, saída) e o treinamento supervisionado para minimizar o erro entre a resposta do modelo e a resposta esperada (ZHANG *et al.*, 2024). O SFT é considerado eficiente, pois permite adaptar rapidamente o modelo a novos domínios sem a necessidade de re-treinamento completo.

Já o **GRPO** é uma técnica baseada em otimização de políticas relativas a grupos, utilizada para aprimorar o desempenho do modelo considerando preferências coletivas de múltiplos usuários ou agentes. No GRPO, o modelo é ajustado para maximizar a satisfação de critérios definidos por grupos, promovendo respostas mais alinhadas a contextos colaborativos ou multiusuário (DAO; VU, 2025). Essa abordagem é especialmente relevante em cenários onde a diversidade de preferências e estratégias é importante para o sucesso da tarefa.

Essas estratégias são relevantes para o presente estudo, pois permitem investigar como diferentes métodos de ajuste podem impactar o desempenho dos LLMs em tarefas de raciocínio espacial.

2.4 Explicabilidade em LLMs

Apesar do alto desempenho, LLMs são frequentemente criticados por seu caráter de "caixa-preta", dificultando o entendimento sobre como tomam decisões e levantando preocupações éticas e de confiança (ZHAO *et al.*, 2023; CAMBRIA *et al.*, 2024; LUO; SPECIA, 2024). A opacidade desses modelos pode resultar em respostas inesperadas, enviesadas ou até mesmo em alucinações, o que reforça a necessidade de técnicas de explicabilidade (*explainability*) para tornar seus mecanismos internos mais transparentes.

A explicabilidade em LLMs pode ser abordada sob diferentes perspectivas. Do ponto de vista do usuário final, explicações claras e acessíveis são essenciais para promover confiança e permitir o uso responsável dos modelos em aplicações sensíveis, como saúde, educação e finanças. Para pesquisadores e desenvolvedores, a explicabilidade atua como ferramenta de diagnóstico, facilitando a identificação de vieses, falhas e oportunidades de aprimoramento dos modelos (ZHAO *et al.*, 2023; LUO; SPECIA, 2024).

As principais técnicas de explicabilidade para LLMs incluem métodos de atribuição de importância a tokens (feature attribution), análise de camadas internas, visualização de mecanismos de atenção e explicações baseadas em exemplos. Recentemente, abordagens baseadas em prompts e cadeias de raciocínio (*chain-of-thought* (WEI *et al.*, 2023)) também têm sido exploradas para tornar o processo de decisão dos modelos mais interpretável (ZHAO *et al.*, 2023). No entanto, o aumento da escala e da complexidade dos LLMs impõe desafios adicionais, tornando a geração de explicações confiáveis e compreensíveis uma tarefa ainda em aberto.

Além disso, a literatura destaca a importância de desenvolver métricas e benchmarks específicos para avaliar a qualidade das explicações geradas, bem como de promover a integração entre avanços em LLMs e técnicas de XAI (Explainable AI) (CAMBRIA *et al.*, 2024). O

avanço conjunto dessas áreas é fundamental para garantir o uso ético, seguro e transparente dos modelos de linguagem em aplicações reais.

2.4.1 LLM-MRI

A biblioteca LLM-MRI (*Large Language Model - Magnetic Resonance Imaging*) é uma ferramenta desenvolvida para facilitar a análise de padrões de ativação em LLMs baseados em *transformer*. Conforme apresentado por (COSTA *et al.*, 2024), a LLM-MRI permite coletar, organizar e projetar em dimensões reduzidas os vetores de ativação gerados pelos modelos ao processarem diferentes entradas. Técnicas de redução de dimensionalidade possibilitam visualizar como as ativações neuronais se distribuem, facilitando a identificação de padrões e a análise das mudanças provocadas por diferentes estratégias de fine-tuning.

No contexto deste trabalho, a LLM-MRI é empregada para investigar como LLMs se adaptam à tarefa de navegação em labirintos ASCII e como as estruturas internas dos modelos evoluem durante o processo de aprendizagem, contribuindo para a análise da interpretabilidade e do raciocínio espacial dos modelos.

3 TRABALHOS RELACIONADOS

Esta seção apresenta a revisão de literatura sobre o tema deste trabalho, com foco em LLMs, fine-tunning e explicabilidade.

3.1 Labirintos como Domínio Estrutural para Raciocínio Espacial

A investigação do raciocínio espacial em modelos de linguagem tem utilizado labirintos como um domínio estruturado e simbólico, capaz de revelar limitações e padrões de generalização dos modelos. O benchmark introduzido por (ZHOU *et al.*, 2024), avalia a suscetibilidade dos LLMs a se apoiarem em atalhos (*shortcuts*) superficiais, ou correlações onde não há relação de causa-efeito, que afetam a robustez dos modelos em tarefas de classificação de texto.

Em outra abordagem, (HSU *et al.*, 2025) propuseram o framework Deep Schema Grounding (DSG), que utiliza LLMs para extrair e estruturar representações simbólicas (schemas) do conceito de labirinto, promovendo um raciocínio mais alinhado à cognição humana ao combinar essas abstrações com modelos multimodais. Essas contribuições reforçam a relevância dos labirintos textuais como ambiente de análise para o comportamento de LLMs em tarefas que exigem planejamento, abstração e robustez interpretativa.

3.2 Raciocínio Espacial em LLMs

O raciocínio espacial em LLMs tem sido explorado por diferentes abordagens, buscando adaptar esses modelos para tarefas que exigem compreensão e manipulação de ambientes estruturados.

O AlphaMaze (DAO; VU, 2025) propõe um processo em duas etapas: inicialmente, o modelo é ajustado via Supervised Fine-Tuning (SFT) para aprender comandos de movimentação em labirintos textuais; em seguida, utiliza-se o Group Relative Policy Optimization (GRPO) para aprimorar o raciocínio e a autocorreção. O MazeBench é empregado para avaliar o desempenho dos modelos em diferentes níveis de dificuldade, evidenciando ganhos após o GRPO.

Em paralelo, (WANG *et al.*, 2024) questionam a vantagem de modelos multimodais em tarefas espaciais, mostrando que LLMs baseados apenas em texto podem superar alternativas multimodais, o que reforça a relevância de investigar estratégias específicas para LLMs textuais. Em contextos tridimensionais, (ZHANG *et al.*, 2025) identificam limitações dos LLMs, enquanto (CHENG *et al.*, 2024) propõem integrar módulos de representação de regiões e informações de profundidade para melhorar a compreensão espacial.

Outras abordagens, como o Chain-of-Symbol (COS) Prompting (HU *et al.*, 2024), convertem descrições em linguagem natural para representações simbólicas intermediárias, otimizando o planejamento espacial e reduzindo o uso de tokens. Já o Visualization of Thought (VoT)

(WU *et al.*, 2024) estimula a geração de representações visuais em ASCII art, inspirando-se na cognição humana para melhorar o acompanhamento de estados e o planejamento de ações. Embora o VoT apresente avanços em determinados cenários, sua eficácia depende das habilidades emergentes dos modelos e da qualidade dos prompts, sendo limitado em tarefas mais complexas ou com modelos menos robustos.

Ainda, mesmo com avanços recentes, variantes como os LRMs, que incorporam mecanismos explícitos de raciocínio, como cadeias de pensamento (*Chain-of-Thought* (WEI *et al.*, 2023)) e auto-reflexão, ainda enfrentam desafios em tarefas de alta complexidade, apresentando limitações na generalização e fenômenos como raciocínio redundante ou ineficiente (SHOJAEE *et al.*, 2025).

Por fim, no contexto deste trabalho, o raciocínio espacial é central, pois o objetivo é investigar como LLMs podem ser ajustados e analisados para resolver labirintos representados em ASCII. As abordagens discutidas na literatura fornecem subsídios para a escolha de técnicas de fine-tuning e avaliação, além de motivar o uso de ferramentas de explicabilidade para compreender como as representações internas dos modelos evoluem ao longo do treinamento.

3.3 Fine-tuning de LLMs para Tarefas Específicas

O fine-tuning de LLMs para tarefas específicas é um tema amplamente investigado, com diferentes estratégias sendo propostas para aprimorar a adaptação dos modelos. Por exemplo, (JIANG *et al.*, 2024) demonstra que o uso de SFT pode melhorar tanto as representações internas quanto a capacidade de generalização, mesmo em modelos visuais, evidenciando a importância do ajuste direcionado para tarefas de raciocínio espacial.

Além disso, (HSIEH *et al.*, 2023) propõem a utilização de *rationales* gerados por LLMs como supervisão adicional em um cenário multitarefa, combinando rótulos e explicações para enriquecer o sinal de treinamento. Essa abordagem, baseada em Chain-of-Thought prompting (WEI *et al.*, 2023), permite que modelos menores alcancem desempenho superior a LLMs maiores, mesmo com menos dados, ao tornar o processo de ajuste mais eficiente e interpretável. No contexto deste trabalho, a integração de racionalizações se mostra relevante para aprimorar a eficiência e a interpretabilidade dos modelos.

3.4 Explicabilidade em LLMs

A explicabilidade em LLMs é um campo em expansão, com abordagens que buscam tornar os modelos mais transparentes e compreensíveis. A biblioteca LLM-MRI (COSTA *et al.*, 2024) destaca-se por permitir a análise e visualização das ativações neuronais, facilitando a interpretação de como os modelos se adaptam a tarefas específicas.

Complementarmente, (WU *et al.*, 2025) propõem o conceito de Usable XAI, que enfatiza a aplicação prática das explicações para diagnóstico e aprimoramento dos modelos. Entre as estratégias discutidas estão métodos de atribuição, análise das ativações internas e explicações baseadas em exemplos, todas relevantes para entender a evolução das representações internas durante o fine-tuning. A integração dessas abordagens contribui para identificar limitações, corrigir vieses e aprimorar o desempenho dos modelos em tarefas que exigem alto grau de interpretabilidade.

4 METODOLOGIA

Esta seção apresenta a metodologia aplicada na investigação, sobre como como LLMs podem aprender, ou como se diferenciam nesta representação, da tarefa de solução de labirintos em ASCII, por meio da análise das mudanças nas ativações internas das redes neurais, após diferentes estratégias de *fine-tuning*. O objetivo desta seção é detalhar os procedimentos adotados, de modo a garantir a replicabilidade do estudo, incluindo preparação dos dados, modelos, métricas e análises estatísticas utilizadas.

4.1 Dados

Foram utilizadas amostras do conjunto de dados de treino, disponibilizado por (DAO; VU, 2025), representados em ASCII, uma vez que esses dados estão disponíveis publicamente e permitiram uma redução considerável no tempo que seria empregado na elaboração dos datasets e ajuste dos modelos.

- **Formato geral dos exemplos**: cada exemplo é um *prompt* textual que instrui o modelo sobre a tarefa, apresenta a grade completa do labirinto com origem e destino e define que a saída deve conter apenas tokens de movimento.
- **Tokenização do labirinto**: a descrição é composta por tokens delimitados no padrão `<|...|>`, incluindo:
  - *Coordenadas*: `<|row-col|>` (ex.: `<|0-0|>`, `<|3-2|>`) indicam a posição absoluta da célula na grade.
  - *Paredes*: um único token resume as paredes presentes na célula, combinando direções com *underscore* (_), por exemplo `<|up_wall|>`, `<|left_right_wall|>`, `<|up_left_right_wall|>` que indicam a existência de paredes acima, à esquerda e à direita e acima, esquerda e direita, respectivamente.
  - *Marcadores especiais*: `<|origin|>`, indica a origem (ponto de partida) e `<|target|>` indica o destino final (ponto de chegada) do labirinto.
  - *Separador*: `<|blank|>` atua como espaçamento explícito entre grupos de tokens/células, reduzindo ambiguidade de fronteiras.
  - *Vocabulário de movimentos* (saída do modelo): tokens que os modelos devem utilizar para descrever a sua resposta, sendo eles, `<|up|>`, `<|down|>`, `<|left|>`, `<|right|>` que representam movimentos para cima, para baixo, para a esquerda e para a direita, respectivamente.

- **Padrão por célula**: cada célula descrita em uma solicitação segue tipicamente o padrão <|row-col|><|wall_pattern|><|blank|>, com este último podendo incluir <|origin|> ou <|target|>, quando aplicável.
- **Formato da resposta**: o modelo deve emitir apenas a sequência de tokens de movimento, separados por espaços, que leva da origem (<|origin|>) ao destino (<|target|>). Nos prompts, incentiva-se, como diretriz adicional para melhor resolução de problemas, a ação "think step-by-step" ("*pense passo a passo*"), em tradução livre. Entretanto, de qualquer forma, a saída final deve conter exclusivamente os tokens de movimento, conforme especificado anteriormente.

4.2 Modelos e Estratégias de Fine-tuning

Foram selecionados três LLMs, todos com 1,5B de parâmetros, compatíveis com a biblioteca LLM-MRI, obtidos via Hugging Face Hub (FACE, 2025). Informações gerais acerca dos modelos são apresentados na Tabela 1.

Tabela 1 – Informações dos modelos utilizados nos experimentos.

Nome	Tipo Ajuste	Parâmetros	Licença
DeepSeek-R1-Distill-Qwen-1.5B	Base	1.5B	MIT
AlphaMaze-v0.2-1.5B-SFT	SFT	1.5B	Apache-2.0
AlphaMaze-v0.2-1.5B	GRPO	1.5B	Apache-2.0

- **DeepSeek-R1-Distill-Qwen-1.5B** ((DEEPSEEK-AI, 2025)): modelo denso destilado a partir do DeepSeek-R1 sobre a família Qwen2.5, utilizado como ponto de partida antes de ajustes específicos (DEEPSEEK-AI, 2025).
- **AlphaMaze-v0.2-1.5B-SFT** ((HQ, 2025)): variante ajustada por SFT, empregada para avaliar o impacto do ajuste supervisionado na tarefa de labirintos (HQ, 2025).
- **AlphaMaze-v0.2-1.5B** ((RESEARCH, 2025)): variante ajustada por GRPO, usada para comparar a dinâmica de aprendizado por otimização de política relativa a preferências (RESEARCH, 2025; DAO; VU, 2025).

De acordo com (DAO; VU, 2025), cada modelo foi treinado separadamente em cada estratégia, com conjuntos de dados de treino específicos para o modelo ajustado com SFT e para o modelo ajustado com GRPO, em que seu conjunto de dados de treino possui orientações adicionais para potencializar sua autocorreção conforme a otimização política relativa a preferências. Ambos os modelos ajustados compartilham a mesma arquitetura e número de parâmetros do modelo base DeepSeek-R1-Distill-Qwen-1.5B. Desta forma, foi reaproveitado todo o processo de treinamento e especialização dos modelos, com diferentes estratégias de *fine-tuning*, conforme discutido na literatura que estão descritas a seguir:

- **Supervised Fine-Tuning (SFT)**: ajuste supervisionado utilizando exemplos de labirintos e suas soluções.
- **Group Relative Policy Optimization (GRPO)**: ajuste baseado em preferências coletivas, visando aprimorar o raciocínio e a autocorreção dos modelos.

4.3 Procedimentos de Processamento, Métricas e Estatística

A obtenção das ativações internas dos modelos foi feita com a utilização da biblioteca LLM-MRI (COSTA *et al.*, 2024), que permite, além da extração, a visualização das ativações neuronais de LLMs. Portanto, aqui estão descritos os procedimentos adotados para o processamento dos dados e a extração das ativações, bem como as análises estatísticas subsequentes.

4.3.1 Pré-processamento e Validação Inicial

O pré-processamento dos dados envolveu as etapas descritas a seguir.

- Obtenção dos arquivos Parquet do *dataset* de treinamento do modelo AlphaMaze-v0.2-1.5B-SFT, contendo os prompts e as respostas geradas pelos modelos.
- Atribuição de *label* binária (*easy* = 0, *complex* = 1) por um limiar de passos (< 10 passos, *easy*; *complex*, caso contrário) para se adequar a análises categóricas, necessário para utilizar a biblioteca LLM-MRI.
- Validação de *embbeddings* extraídos dos modelos pela biblioteca LLM-MRI com modelos de aprendizado de máquina de regressão logística. Validação realizada antes e depois da aplicação da redução de dimensionalidade para assegurar a consistência do funcionamento da biblioteca. De acordo com os resulados obtidos na validação dos *embeddings*, foi possível confirmar o funcionamento adequado da biblioteca LLM-MRI para extração das ativações dos modelos selecionados. Sendo que para o resultado do modelo de regressão logística aplicado sobre os *embeddings* antes da redução de dimensionalidade, obteve-se uma acurácia de 100%.

4.3.2 Métricas de Ciências das Redes

As métricas de ciências das redes utilizadas para caracterizar os grafos de ativações para as camada dos modelos estão descritas a seguir. Os grafos utilizados foram construídos conforme a LLM-MRI. As métricas dependentes de caminhos foram calculadas sobre a maior componente conexa (Largest Connected Component - LCC).

- **Número de Nós** ($|V|$): número total de nós (ordem) do grafo.

- **Número de Arestas** ($|E|$): número total de arestas do grafo.
- **Grau Médio** ($\bar{k}$): média do grau dos nós.
- **Densidade** (ρ): fração de arestas observadas em relação ao máximo possível. Valores mais altos indicam conectividade mais densa.
- **Assortatividade** (r): coeficiente de assortatividade. Valores positivos indicam tendência de nós de alto grau conectarem-se entre si; negativos indicam conexões preferenciais entre nós de alto e baixo grau.
- **Diâmetro** (D): maior distância entre pares de nós na LCC do grafo, isto é, comprimento do caminho mais curto máximo. Quando o grafo não é totalmente conexo, D é calculado na LCC.
- **Comprimento Médio de Caminho** ($\bar{L}$): distância média entre todos os pares de nós na LCC.

4.3.3 Amostragem para Inferência de Distribuições

Empregou-se um protocolo de amostragem repetida para estimar a variabilidade das métricas de rede, sem amostragem repetida de prompts em um mesmo experimento. Em cada experimento modelos foram comparados sob entradas idênticas.

Em cada experimento, foram selecionados 40 prompts distintos (sem reposição) e foi repetido o procedimento em 1000 experimentos, mantendo o mesmo lote (40 prompts) por experimento entre os três modelos. Além disso, foi realizado uma segunda bateria de 1000 experimentos, neste caso, considerando os dados do grafo das ativações apenas das últimas cinco camadas, para investigar o efeito do fine-tunning nas camadas mais especializadas. Os passos por experimento estão descritos com maior detalhamento a seguir.

1. Selecionou-se um lote de 40 prompts;
2. Coletaram-se as ativações em cada modelo via LLM-MRI;
3. Obteve-se o grafo das ativações;
4. Calcularam-se as métricas mencionadas anteriormente.
5. Registrou-se as métricas e o tempo total de processamento por experimento e modelo.

Sementes pseudoaleatorias foram fixadas para reprodutibilidade, bem como versões de bibliotecas foram anotadas. Para cada métrica e modelo, foram gerados: histogramas; estimativas de densidade por núcleo (*Kernel Density Estimation* – KDE) e curvas de média cumulativa por índice de experimento, visando inspecionar estabilização. Este mesmo procedimento foi

replicado para a configuração de “todas as camadas” e para “últimas cinco camadas” de ativações.

4.3.4 Significância Estatística

Ao término do procedimento de amostragem, foram realizados testes de significância estatística entre as distribuições das métricas de rede dos três modelos, para as duas configurações especificadas (todas as camadas e últimas cinco camadas). Inicialmente, foi aplicado o teste ANOVA de uma via para verificar a existência de diferenças globais entre as distribuições das métricas dos três modelos. Em seguida, foram realizados testes t pareados entre os pares de modelos (Base vs SFT e Base vs GRPO) para identificar quais pares apresentavam diferenças estatisticamente significativas. As hipóteses estabelecidas para essa verificação estatística estão descritas a seguir.

- **Hipótese nula (H0)**: as distribuições de cada métrica são equivalentes entre os modelos comparados.
- **Hipótese alternativa (H1)**: existe diferença estatisticamente significativa entre pelo menos dois modelos para a métrica analisada.

4.4 Máquina e Recursos Computacionais

Os experimentos foram executados em uma única máquina, utilizando exclusivamente o processador (CPU) do equipamento, embora uma GPU estivesse disponível e funcional no sistema, não foi necessária a sua utilização nos procedimentos descritos neste trabalho. Os tempos reportados referem-se ao tempo de processamento medido por experimento, registrados durante a extração das ativações via LLM-MRI e o cálculo das métricas de rede.

4.4.1 Tempos de Execução

- Duração total (1000 experimentos para todas as camadas): **64,24 horas**.
- Duração média por experimento (todas as camadas): **77,09 segundos**.
- Duração total (1000 experimentos para últimas 5 camadas): **88,68 horas**.
- Duração média por experimento (últimas 5 camadas): **106,42 segundos**.

4.4.2 Configuração da máquina

As informações a seguir foram obtidas a partir do gerenciador de tarefas do Windows (captura de configuração e métricas no momento da execução/registro):

- **CPU**: 13th Gen Intel(R) Core(TM) i7-13700HX (Velocidade base: 2,10 GHz; Núcleos: 16; Processadores lógicos: 24).
- **Memória (RAM)**: 16,0 GB (SODIMM, 4800 MT/s; 2 de 4 slots usados).
- **GPU (disponível, não utilizada)**: NVIDIA GeForce RTX 4050 Laptop GPU; Memória dedicada da GPU: 6,0 GB.
- **Armazenamento:** SSD NVMe (477 GB).

4.5 Síntese Metodológica e Hipóteses Iniciais

Os procedimentos descritos nesta seção estabelecem o fluxo experimental aplicado para investigar como diferentes estratégias de *fine-tuning* impactam as ativações internas de LLMs na tarefa de solução de labirintos em ASCII. Com a aplicação dessa metodologia, serão examinadas as seguintes hipóteses:

H1: Estratégias distintas de *fine-tuning* (SFT e GRPO) induzem padrões diferentes de ativação interna, refletindo abordagens variadas de raciocínio espacial e de representação da tarefa.

H2: A análise das ativações neuronais por meio da LLM-MRI permite identificar alterações estruturais e padrões emergentes associados ao aprendizado da tarefa, contribuindo para a compreensão dos mecanismos internos dos modelos.

Na seção seguinte, estão apresentados os resultados para embasar a discussão sobre as hipóteses formuladas.

5 RESULTADOS

Os resultados mais relevantes obtidos estão apresentados nesta seção e estruturados de maneira que, para cada uma das configurações mencionadas, e algumas das métricas descritas na Seção 4.3.2, são apresentadas as curvas de médias cumulativas e estimativas de densidade por núcleo (KDE), além dos respectivos resultados dos testes de significância estatística.

5.1 Resultados Considerando Todas as Camadas de Ativações

A seguir, estão apresentados os resultados da configuração que considerou as ativações de todas as camadas, capturadas com a biblioteca LLM-MRI, gerados a partir da entrada dos prompts de labirintos pelos modelos.

- **Número de Nós ($|V|$) e Número de Arestas ($|E|$)**: não foram observadas diferenças significativas entre os modelos, resultando em distribuições bastante similares e com pouca variabilidade entre os experimentos realizados. Dessa forma, não foram incluídas figuras para estas métricas.

5.1.1 Grau Médio ($\bar{k}$)

A média cumulativa dos graus médios obtidos para os três modelos, considerando todas as camadas, estão apresentados na Figura 2. Na qual, observa-se que as curvas convergem para valores próximos, indicando, ao final, uma média estável maior para o modelo ajustado com GRPO, seguido do modelo Base e, por fim, o modelo ajustado com SFT.

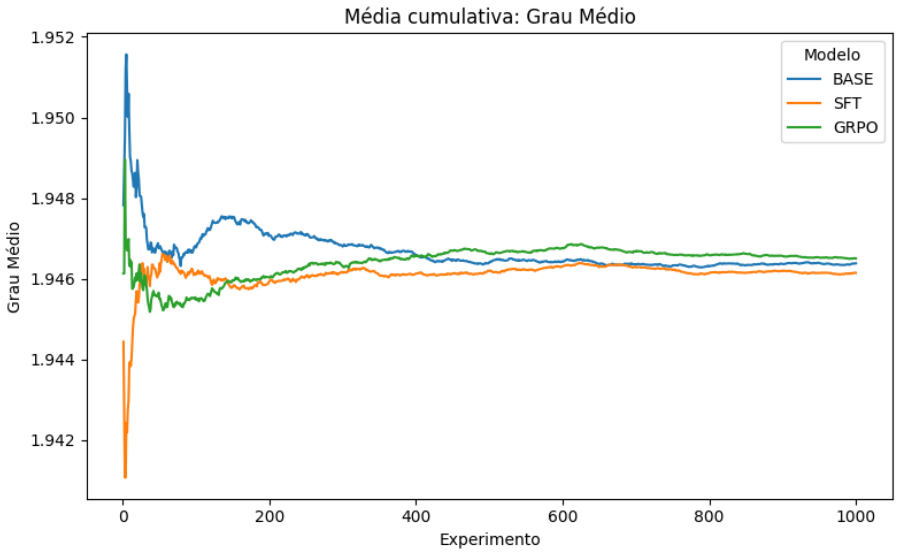


Figura 2 – Média cumulativa do Grau Médio ($\bar{k}$).

Na Figura 3, observa-se que os três modelos apresentaram distribuições bastante similares para o KDE do grau médio. Apesar de médias muito próximas, pode-se notar que o modelo os modelos ajustados, SFT e GRPO, exibem um pico ligeiramente mais acentuado em relação ao modelo Base, sugerindo uma maior concentração de valores em torno da média, com este último apresentando uma distribuição levemente mais à esquerda.

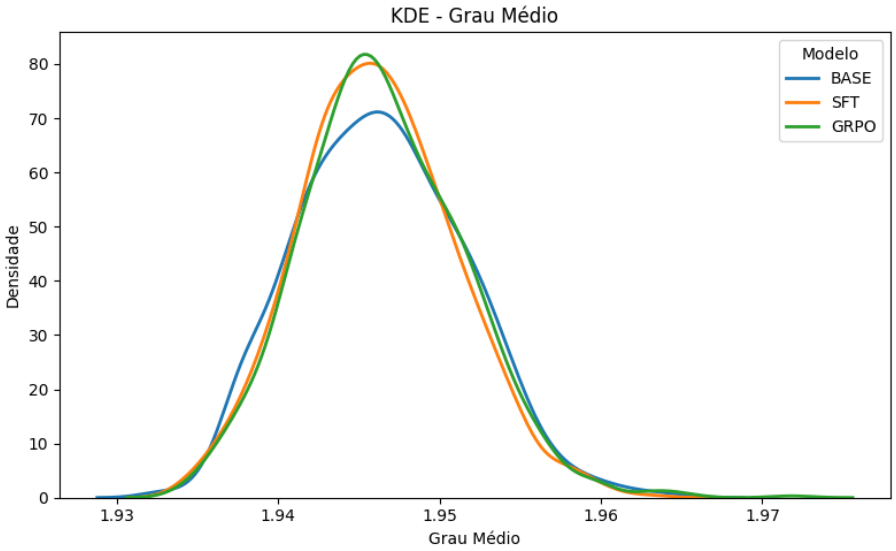


Figura 3 – KDE do Grau Médio ($\bar{k}$).

5.1.2 Densidade (ρ)

Nota-se, ao analisar a figura da média cumulativa da densidade do grafo das ativações na Figura 4 que, novamente, os três modelos convergem para valores muito próximos com GRPO apresentando a maior média, seguido do modelo Base e SFT.

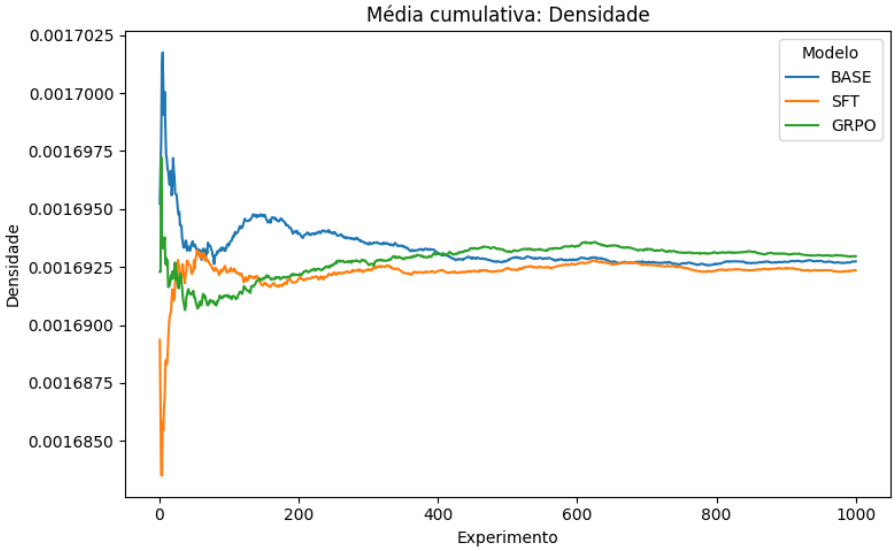


Figura 4 – Média cumulativa da Densidade (ρ).

Conforme ilustrado na Figura 5, as distribuições estimadas por KDE também revelam um comportamento bastante semelhante àquela análisado para o grau médio anteriormente. Do ponto de vista de redes complexas, embora sutis, essa distribuição sugere que os ajustes realizados no modelo base tende a produzir grafos de ativações com maior compactação estrutural, refletida em densidades ligeiramente maiores.

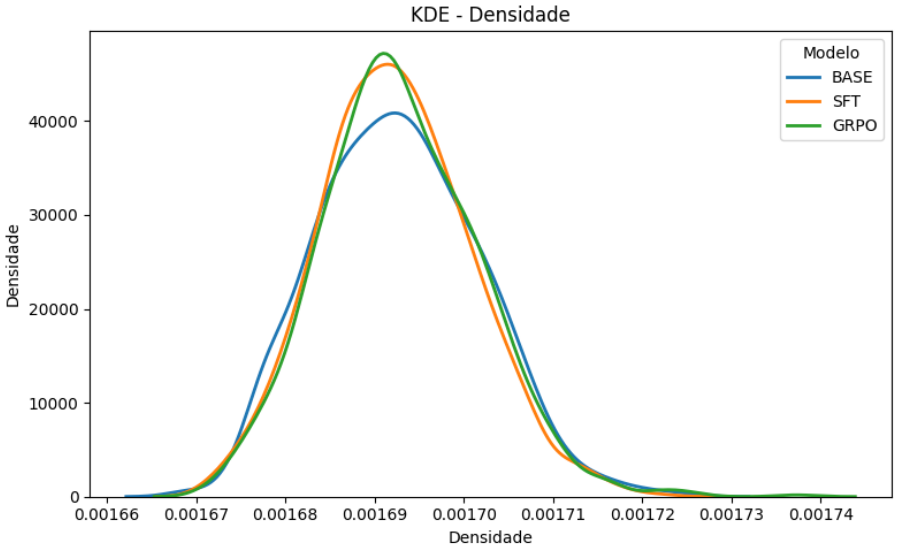


Figura 5 – KDE da Densidade (ρ).

5.1.3 Assortatividade (r)

Observa-se que a evolução da média cumulativa da assortatividade, apresentada na Figura 6, indica que os três modelos convergem para valores negativos próximos, indicando tendência geral a uma conectividade disassortativa ao longo dos experimentos, com o modelo Base tendendo a apresentar valores médios ligeiramente menos negativos que os modelos ajustados com SFT e GRPO.

As distribuições estimadas, na Figura 7, revelam picos concentrados nas regiões próximas de zero e em valores levemente negativos, apesar da proximidade entre as curvas, nota-se que os modelos ajustados com SFT e GRPO exibem distribuições ligeiramente deslocadas e concentradas para regiões mais negativas. Podemos inferir que os ajustes realizados via SFT e GRPO tendem a intensificar, ainda que de forma sutil, a característica disassortativa das redes em comparação ao modelo Base.

5.1.4 Diâmetro (D)

A Figura 8 apresenta a média cumulativa do diâmetro. Os três modelos convergem para valores próximos, com o modelo Base ligeiramente maior e médias ligeiramente menores após SFT e GRPO, sugerindo grafos de ativação um pouco mais compactos que o modelo Base.

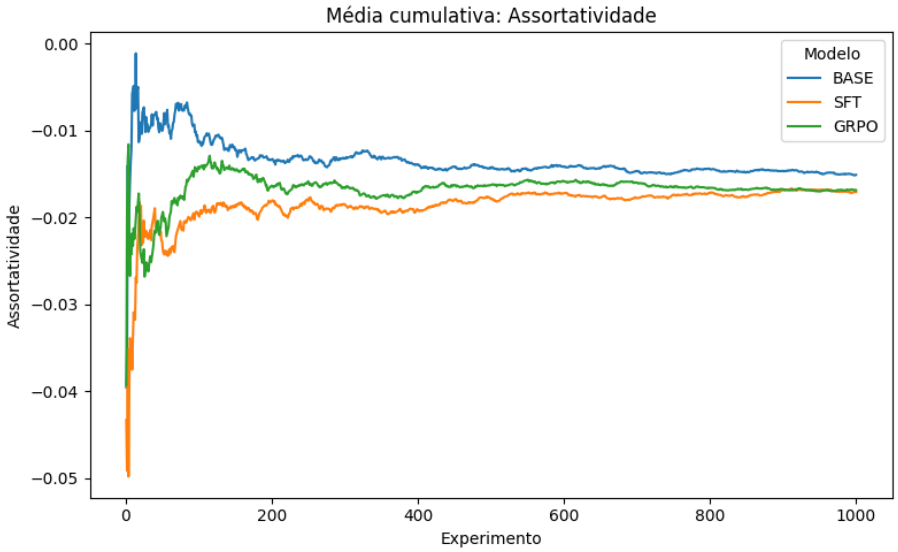


Figura 6 – Média cumulativa da Assortatividade (r).

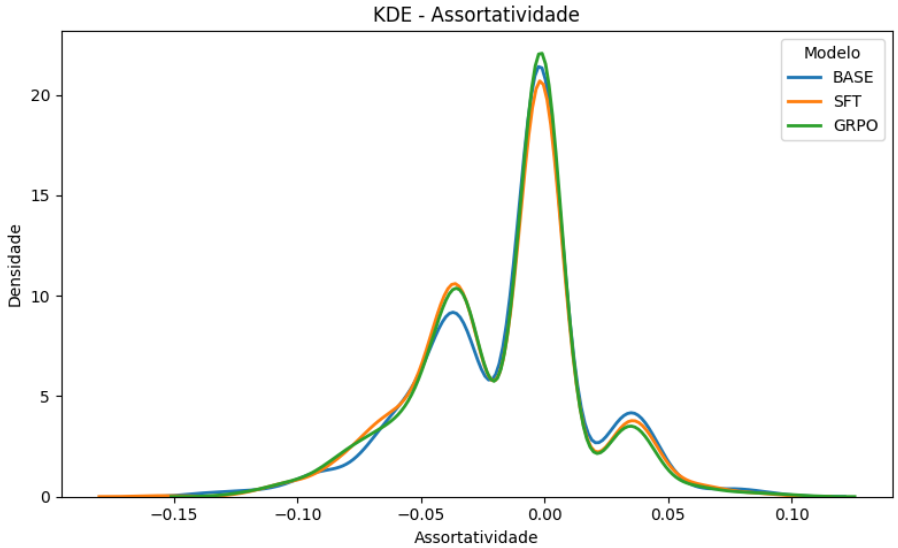


Figura 7 – KDE da Assortatividade (r).

Na Figura 9, as curvas KDE dos três modelos quase se sobrepõem, nos picos e na leve cauda à direita. Embora as distribuições de densidade sejam visualmente quase idênticas, a análise das médias cumulativas clarifica que os ajustes realizados via SFT e GRPO tendem a reduzir sutilmente o diâmetro médio dos grafos de ativação.

5.1.5 Comprimento Médio do Caminho ($\bar{L}$)

A evolução da média cumulativa do comprimento médio do caminho é apresentada na Figura 10. Pode-se perceber que o modelo Base tende a estabilizar em um valor médio superior em comparação aos modelos ajustados. Em contraste, os modelos SFT e GRPO convergem para valores inferiores e bastante próximos entre si, com o GRPO sendo ligeiramente maior.

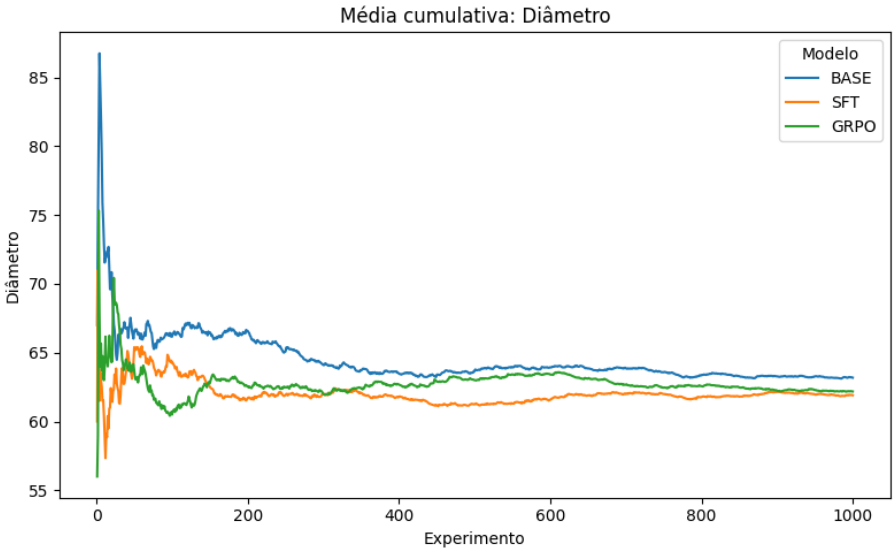


Figura 8 – Média cumulativa do Diâmetro (D).

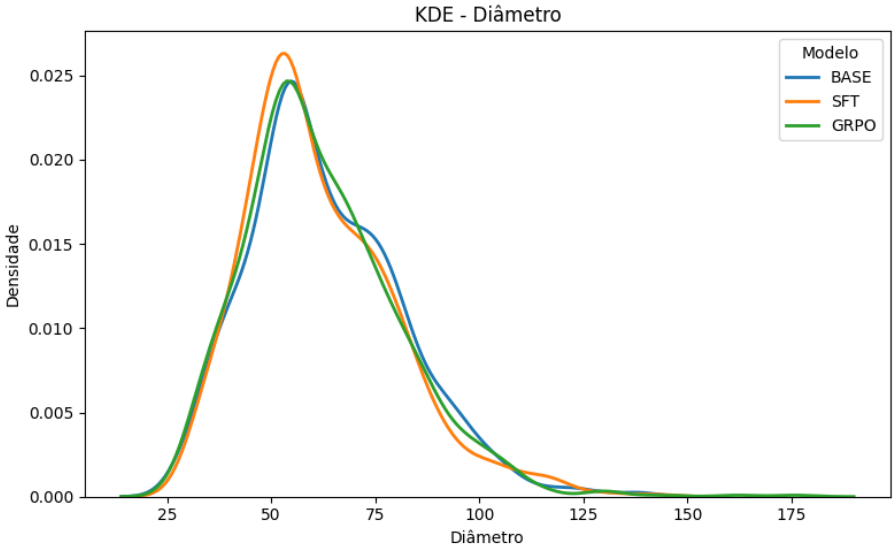


Figura 9 – KDE do Diâmetro (D).

As distribuições estimadas por KDE, ilustradas na Figura 11, condizem com o comportamento observado nas médias cumulativas. As diferenças, picos ligeiramente mais acentuados e o leve deslocamento à esquerda, indicam que os ajustes realizados tendem a reduzir o comprimento médio do caminho na rede de ativações, sugerindo uma maior eficiência na conectividade global quando comparada ao modelo original.

5.2 Resultados Considerando Apenas as Últimas Cinco Camadas de Ativações

Nesta seção, estão apresentados os resultados obtidos a partir dos experimentos realizados, considerando apenas as últimas cinco camadas do embbeddings gerados aos prompts de labirintos pelos modelos, capturados com a biblioteca LLM-MRI.

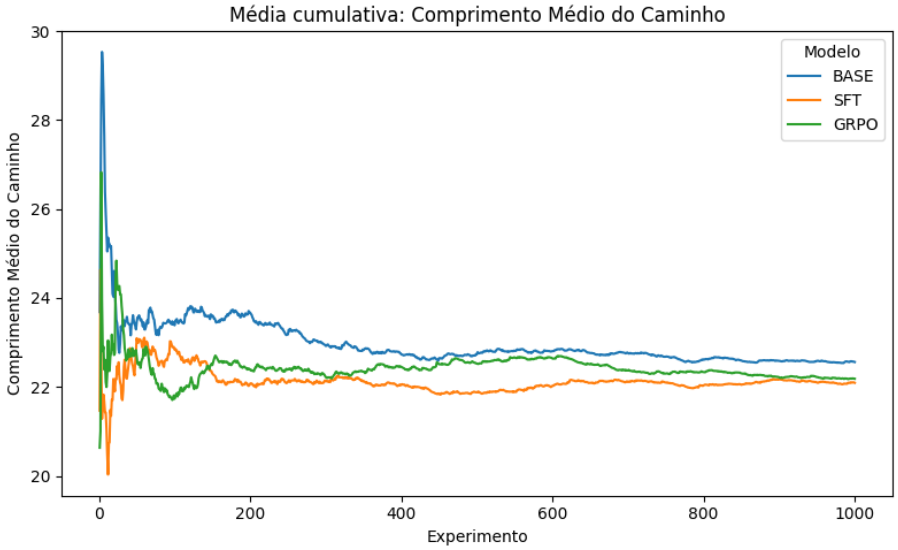


Figura 10 – Média cumulativa do Comprimento Médio do Caminho ($\bar{L}$).

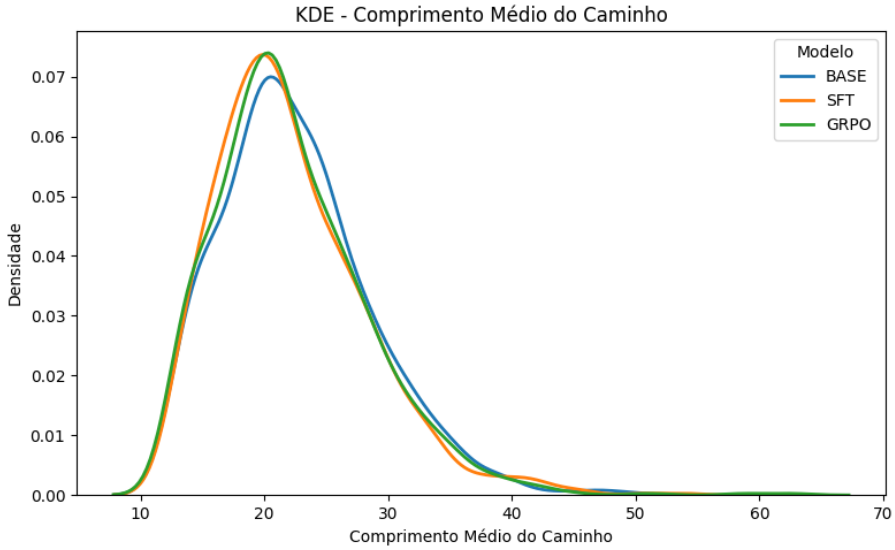


Figura 11 – KDE do Comprimento Médio do Caminho ($\bar{L}$).

- **Número de Nós ($|V|$) e Número de Arestas ($|E|$)**: de modo similar ao observado na seção anterior, não foram observadas diferenças significativas entre os modelos, resultando em distribuições bastante similares e com pouca variabilidade entre os experimentos realizados. Dessa forma, não foram incluídas figuras para estas métricas.

- **Grau Médio ($\bar{k}$), Diâmetro (D) e Comprimento Médio do Caminho ($\bar{L}$)**: para estas métricas, não foram observadas diferenças representativas. Foram obtidas distribuições bastante similares entre os modelos, com diferenças mínimas de sobreposição entre as curvas de KDE e valores recorrentes, obtidos durante os experimentos, para as métricas calculadas e médias relativamente reduzidas, se comparadas àquelas obtidas quando consideradas todas as camadas. Sendo assim, figuras para estas métricas não foram incluídas.

5.2.1 Densidade (ρ)

Para a densidade, levando em consideração apenas as últimas cinco camadas de ativações, pode-se observar, na Figura 12, a evolução da média cumulativa. Apesar de médias estabilizadas próximas entre os modelos, é interessante notar a diferença obtida no valor da média, relativamente maior, quando comparada àquela obtida, para a mesma métrica, considerando o cenário de todas as camadas.

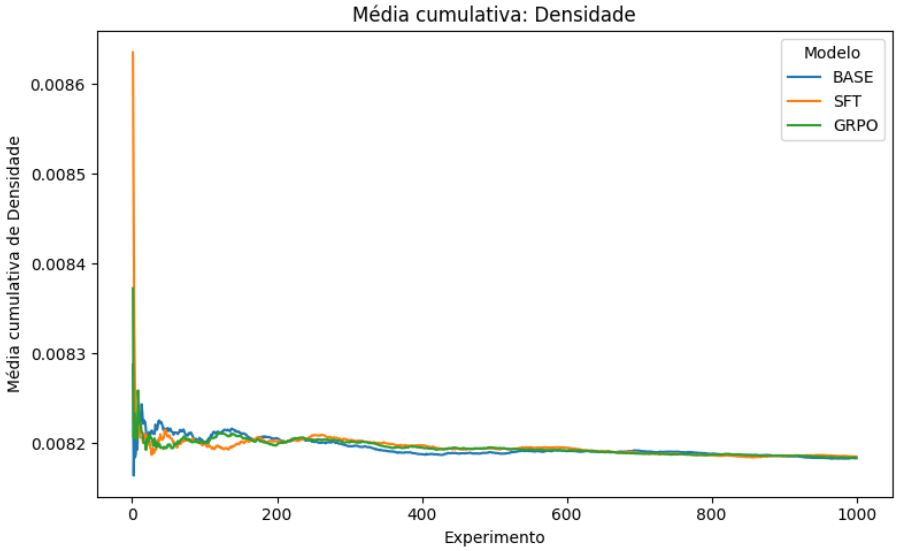


Figura 12 – Média cumulativa da Densidade (ρ)

Conforme ilustrado na Figura 13, as distribuições estimadas por KDE revelam comportamentos muito parecidos entre os modelos. É possível visualizar alguns picos de densidade variados no domínio, evidenciando a repetição de certos valores de densidade ao longo dos experimentos realizados. Apesar disso, as curvas apresentam uma sobreposição considerável, com poucas diferenças visuais entre os modelos e o modelo GRPO apresentando uma leve tendência a valores de densidade mais concentrados.

5.2.2 Assortatividade (r)

É apresentada a evolução da média cumulativa da assortatividade, considerando apenas as últimas cinco camadas, na Figura 14. Percebe-se que o comportamento reflete a tendência observada na análise global em que todos os modelos convergem para valores negativos, caracterizando redes disassortativas. Entretanto, com base no valor estável da média, os modelos Base e ajustados com apresentam uma intensificação da disassortatividade nas camadas finais, quando comparados ao cenário que considera todas as camadas.

Para a assortatividade, pode-se observar, na Figura 15, as distribuições estimadas por KDE. De modo distinto, ao que foi apresentado para a assortatividade considerando todas as camadas, as curvas exibem dois picos principais de concentração em regiões mais negativas

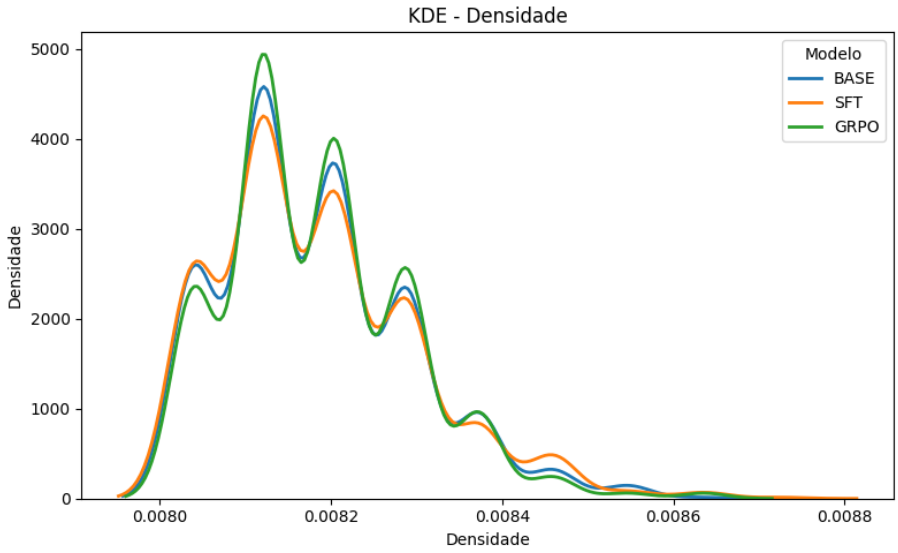


Figura 13 – KDE da Densidade (ρ)

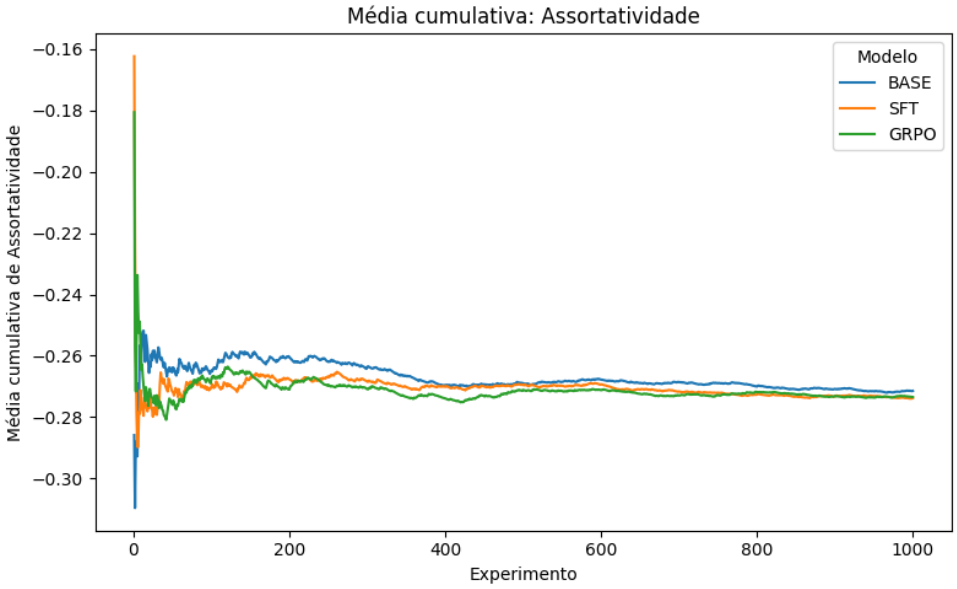


Figura 14 – Média cumulativa da Assortatividade (r).

do domínio, sugerindo uma maior desassortatividade nas redes formadas pelas últimas cinco camadas. Além disso, visualmente, as curvas apresentam uma sobreposição considerável, com poucas diferenças visuais entre os modelos.

5.3 Testes de Significância Estatística

Para avaliar a significância estatística das diferenças nos gráficos de distribuições e médias observadas para as métricas analisadas, foram realizados testes de hipótese apropriados. Utilizou-se o teste ANOVA para comparar as médias das métricas entre os três modelos, além de Testes t pareados para comparações específicas entre pares de modelos (BASE vs SFT e BASE vs GRPO).

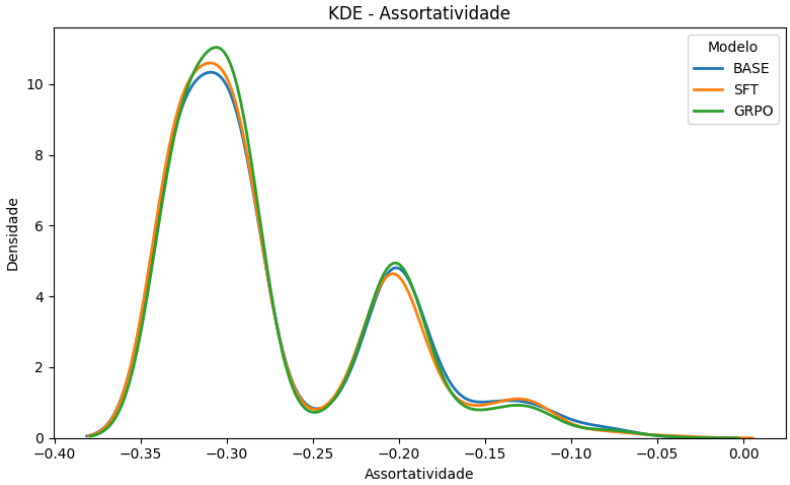


Figura 15 – KDE da Assortatividade (r).

De acordo com os testes, as diferenças, devido ao ajuste dos modelos (SFT ou GRPO), nas estruturas do grafo de ativações neurais dos modelos **não são estatisticamente significativas** ($p < 0.05$). Do ponto de vista estatístico, isto sugere que as sutis variações observadas, nas distribuições e médias das métricas, podem não ser relevantes o suficiente para serem consideradas significativas.

A Tabela 2, a seguir, apresenta os valores *p-value*'s obtidos nos Testes t e ANOVA realizados para as métricas relevantes, considerando todas as camadas dos modelos.

Tabela 2 – p-values ANOVA e Testes t pareados (Base vs SFT, Base vs GRPO) – Todas as camadas.

Métrica	ANOVA	Base vs SFT	Base vs GRPO
Número de Nós	0.3125	0.3553	0.5641
Grau Médio	0.2682	0.2932	0.5934
Densidade	0.2882	0.3193	0.5821
Assortatividade	0.3473	0.1904	0.2345
Diâmetro	0.2640	0.1191	0.2272
Comprimento Médio do Caminho	0.1927	0.0851	0.1693

Os mesmos testes foram realizados para o cenário considerando apenas as últimas cinco camadas do grafo de ativações neuronais dos modelos, resultados de *p-value*'s descritos na Tabela 3 e, de forma semelhante, não indicaram diferenças estatisticamente significativas entre o modelo base e os modelos ajustados.

Tabela 3 – p-values ANOVA e Testes t pareados (Base vs SFT, Base vs GRPO) – Últimas 5 camadas.

Métrica	ANOVA	Bas3 vs SFT	Base vs GRPO
Número de Nós	0.9282	0.7060	0.8496
Grau Médio	0.9257	0.7094	0.9104
Densidade	0.9205	0.6960	0.8902
Assortatividade	0.6877	0.4310	0.4893
Diâmetro	0.4160	0.4847	0.1785
Comprimento Médio do Caminho	0.5064	0.4727	0.2395

Para os dois cenários verificados, os testes de significância estatística da métrica Número de Arestas, por apresentarem valores, no decorrer dos experimentos, muito próximos entre os diferentes modelos, com pouca variabilidade e muito recorrentes, foi omitida a apresentação dos resultados dos testes estatísticos para esta métrica. A próxima seção apresenta a discussão dos resultados obtidos, interpretando os achados integrando com os objetivos do estudo e das hipóteses formuladas inicialmente.

6 CONCLUSÃO

Nesta seção são discutidos os resultados obtidos, relacionando-os com as hipóteses formuladas, os gráficos apresentados na seção anterior e o entendimento subjacente deste estudo. Os principais pontos abordados incluem: análise dos prompts utilizados, interpretação sobre os resultados de métricas dos grafos de ativações recorrerentes, limitações do estudo,sugestões para trabalhos futuros e uma síntese final relacionando os achados com as hipóteses iniciais.

6.1 Análise dos Prompts Utilizados

Os prompts utilizados para gerar os grafos de ativações são fundamentais para compreender os resultados obtidos. A escolha para cada um deles foi realizada com sementes pseudoaleatórias, buscando diversidade e representatividade da base completa de dados.

No entanto, é importante reconhecer que dado a natureza genérica e bastante similar dos prompts, pode ter havido limitações na capacidade de capturar nuances específicos que poderiam influenciar as métricas dos grafos de ativações, provocando, até mesmo, uma alteração no resultado relativo à significância estatística obtida relacionada às métricas análisadas.

Os prompts si possuíam variações unicamente na estrutura da configuração do cenário do labirinto, mantendo sempre a mesma instrução de resolução e objetivo como entrada para os modelos, o que pode ter impactado na diversidade dos grafos gerados e consequentemente nas métricas analisadas, bem como na repetição de padrões observados para essas métricas calculadas.

Futuras investigações poderiam explorar a utilização de prompts mais variados, com estruturas de labirintos diversificadas, inclusive, instruções diferentes, para avaliar como diferentes contextos podem impactar as estruturas dos grafos de ativações gerados.

6.2 Resultados das Métricas dos Grafos de Ativações Recorrentes

Especialmente durante a análise das métricas das ativações envolvendo o cenário que considerou apenas as últimas cinco camadas de ativações dos grafos, percebeu-se uma menor variabilidade nos resultados obtidos, de um modo geral, para todas as métricas analisadas.

Essa redução na variabilidade pode ser atribuída ao fato de que, ao focar apenas nas últimas camadas, o modelo está considerando uma parte mais específica e refinada do processo de ativação, o que tende a resultar em grafos mais homogêneos e essa homogeneidade pode levar a uma menor dispersão nos valores das métricas, refletindo uma consistência maior nas estruturas dos grafos gerados a partir dessas camadas finais.

Esse comportamento pode ser percebido ao avaliar as figuras 12 e 14 da Seção 5.2, onde as médias cumulativas das métricas de densidade e assortatividade, respectivamente,

apresentam curvas muito mais próximas entre si, praticamente coincidentes ao final. Isto indica uma menor variação nos valores dessas métricas, quando comparadas aos grafos completos, efeito que não é percebido com tanta intensidade em nenhuma das métricas analisadas na Seção 5.1.

Além disso, ao analisar as distribuições estimadas por KDE para as métricas dos grafos considerando apenas as últimas cinco camadas, como apresentado nas Figuras 13 e 15, observa-se que as curvas estão ainda mais sobrepostas, indicando uma similaridade ainda maior entre os modelos ajustados em comparação ao modelo Base. Por fim, também com relação às figuras de KDE, é possível verificar diversos picos mais pronunciados no domínio da métrica, sugerindo que os valores estão mais concentrados em torno de determinados pontos, reforçando a ideia de menor variabilidade nos resultados obtidos.

6.3 Limitações do Estudo

Apesar dos esforços para conduzir uma análise robusta, este estudo apresenta algumas limitações que devem ser consideradas ao interpretar os resultados:

- **Geração das Ativações**: a extração das ativações ocorre apenas considerando o token CLS e não leva em conta os tokens subsequentes que podem conter informações relevantes para a resolução do labirinto. Isso pode limitar a compreensão completa das representações internas dos modelos.
- **Diversidade dos Prompts**: a escolha dos prompts, embora tenha buscado diversidade, pode não ter sido suficientemente ampla para capturar todos os nuances possíveis na geração dos grafos de ativações. Prompts mais variados poderiam ter proporcionado uma visão mais completa do comportamento dos modelos.
- **Tamanho da Amostra**: o número de prompts utilizados pode ter sido limitado, o que pode afetar a generalização dos resultados. Uma amostra maior poderia fornecer uma base mais sólida para as análises estatísticas em custo de maior necessidade de poder computacional.
- **Métricas Analisadas**: as métricas escolhidas para análise são relevantes, entretanto outras poderiam ser exploradas para obter uma compreensão mais completa. Por exemplo, a clusterização, que não foi abordada neste estudo devido a uma limitação estrutural dos grafos gerados.

6.4 Trabalhos Futuros

Como forma de direcionar futuras investigações no tema deste estudo, a seguir estão sugeridas algumas possibilidades para trabalhos futuros.

- Investigar a possibilidade do uso de embbeddings que considerem tokens além do CLS, buscando capturar informações mais adiante sobre o processo de resolução do labirinto.
- Investigar o impacto de diferentes tipos de prompts, incluindo variações mais complexas e contextuais, para entender como a diversidade na entrada afeta as métricas dos grafos.
- Obter as ativações dos modelos para as saídas em diferentes etapas da resolução de uma mesma tarefa em uma mesma solicitação, buscando entender como as ativações evoluem ao longo do processo de geração da solução final do labirinto, com o intuito também de analisar como as métricas dos grafos de ativações se comportam em cada etapa.
- Analisar a influência de diferentes técnicas de *fine-tuning*, além do SFT e GRPO, na estrutura dos grafos de ativações, avaliando se outras abordagens resultam em mudanças significativas nas métricas analisadas, além da avaliação de outras métricas de grafos que possam fornecer insights adicionais sobre as mudanças estruturais provocadas pelos diferentes métodos de ajuste fino.

6.5 Conclusão

Os resultados apresentados neste estudo fornecem um bom direcionamento para compreender o impacto do *fine-tuning* em modelos de linguagem no contexto de resolução de labirintos em ASCII. As análises das métricas dos grafos de ativações revelaram mudanças sutis, apesar de não significativas estatisticamente, nas estruturas dos grafos gerados pelos modelos ajustados em comparação ao modelo Base.

Essas mudanças sugerem que o *fine-tuning* pode influenciar a forma como os modelos processam e representam informações, mesmo que essas alterações não sejam drasticamente evidentes nas métricas analisadas. A redução na variabilidade observada ao focar nas últimas cinco camadas de ativações destaca a importância de considerar diferentes níveis de abstração dentro dos modelos para compreender plenamente o impacto do ajuste fino.

Por fim, as sugestões para trabalhos futuros apontam para diversas direções promissoras que podem aprofundar a compreensão sobre o comportamento dos modelos de linguagem e suas representações internas, contribuindo para avanços na área de processamento de linguagem natural.

REFERÊNCIAS

CAMBRIA, E. *et al.* **XAI meets LLMs: A Survey of the Relation between Explainable AI and Large Language Models**. 2024. Disponível em: https://arxiv.org/abs/2407.15248.

CHENG, A.-C. *et al.* **SpatialRGPT: Grounded Spatial Reasoning in Vision Language Models**. 2024. Disponível em: https://arxiv.org/abs/2406.01584.

COSTA, L. *et al.* LLM-MRI Python module: a brain scanner for LLMs. *In*: **Anais Estendidos do XXXIX Simpósio Brasileiro de Bancos de Dados**. Porto Alegre, RS, Brasil: SBC, 2024. p. 125–130. ISSN 0000-0000. Disponível em: https://sol.sbc.org.br/index.php/sbbd_estendido/article/view/30782.

DAO, A.; VU, D. B. **AlphaMaze: Enhancing Large Language Models' Spatial Intelligence via GRPO**. 2025. Disponível em: https://arxiv.org/abs/2502.14669.

DEEPSEEK-AI. **DeepSeek-R1-Distill-Qwen-1.5B**. 2025. https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-1.5B. Cartão de modelo do Hugging Face; license: MIT; Derivado de Qwen2.5 (Apache-2.0); Acessado em: 7 de julho de 2025.

DEVLIN, J. *et al.* **BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**. 2019. Disponível em: https://arxiv.org/abs/1810.04805.

FACE, H. **Hugging Face Hub: The Model Hub**. 2025. https://huggingface.co/docs/hub/models-the-hub. Página de documentação; Acessado em: 7 de julho de 2025.

HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. **Neural Computation**, v. 9, n. 8, p. 1735–1780, 11 1997. ISSN 0899-7667. Disponível em: https://doi.org/10.1162/neco.1997.9.8.1735.

HQ jan. **AlphaMaze-v0.2-1.5B-SFT**. 2025. https://huggingface.co/jan-hq/AlphaMaze-v0.2-1.5B-SFT. Cartão de modelo do Hugging Face; license: Apache-2.0; Acessado em: 7 de julho de 2025.

HSIEH, C.-Y. *et al.* **Distilling Step-by-Step! Outperforming Larger Language Models with Less Training Data and Smaller Model Sizes**. 2023. Disponível em: https://arxiv.org/abs/2305.02301.

HSU, J. *et al.* **What Makes a Maze Look Like a Maze?** 2025. Disponível em: https://arxiv.org/abs/2409.08202.

HU, H. *et al.* **Chain-of-Symbol Prompting Elicits Planning in Large Langauge Models**. 2024. Disponível em: https://arxiv.org/abs/2305.10276.

JIANG, X. *et al.* **Supervised Fine-tuning in turn Improves Visual Foundation Models**. 2024. Disponível em: https://arxiv.org/abs/2401.10222.

JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models**. 3rd. ed. Stanford, CA: Draft, 2025. Draft of January 12, 2025. Copyright ©2024. All rights reserved. Disponível em: https://web.stanford.edu/~jurafsky/slp3/ed3book.pdf.

LUO, H.; SPECIA, L. **From Understanding to Utilization: A Survey on Explainability for Large Language Models**. 2024. Disponível em: https://arxiv.org/abs/2401.12874.

MIKOLOV, T. *et al.* **Distributed Representations of Words and Phrases and their Compositionality**. 2013. Disponível em: https://arxiv.org/abs/1310.4546.

RAFFEL, C. *et al.* **Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer**. 2023. Disponível em: https://arxiv.org/abs/1910.10683.

RESEARCH, M. **AlphaMaze-v0.2-1.5B**. 2025. https://huggingface.co/Menlo/AlphaMaze-v0.2-1.5B. Cartão de modelo do Hugging Face; license: Apache-2.0; Acessado em: 7 de julho de 2025.

SADIK, A. M. *et al.* A Comprehensive and Comparative Study of Maze-Solving Techniques by Implementing Graph Theory. *In*: **2010 International Conference on Artificial Intelligence and Computational Intelligence**. [*S.l.*: *s.n.*], 2010. v. 1, p. 52–56.

SHOJAEE, P. *et al.* **The Illusion of Thinking: Understanding the Strengths and Limitations of Reasoning Models via the Lens of Problem Complexity**. 2025. Disponível em: https://arxiv.org/abs/2506.06941.

TUNSTALL, L.; WERRA, L. von; WOLF, T. **Natural Language Processing with Transformers**. 1. ed. Sebastopol, CA, USA: O'Reilly Media, Inc., 2022. First Edition, February 2022. ISBN 978-1-098-10324-8. Disponível em: https://www.oreilly.com/library/view/natural-language-processing/9781098103248/.

VARTAK, V. U. **Maze Solver Robot using A* algorithm**. set. 2023. Dissertação (Master's thesis) — California State University, Northridge, Northridge, set. 2023. Committee Members: Saba Janamian, MD Sahabul Alam. Disponível em: http://hdl.handle.net/20.500.12680/0c483r787.

VASWANI, A. *et al.* Attention is All you Need. *In*: GUYON, I. *et al.* (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2023. v. 30. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.

WANG, J. *et al.* **Is A Picture Worth A Thousand Words? Delving Into Spatial Reasoning for Vision Language Models**. 2024. Disponível em: https://arxiv.org/abs/2406.14852.

WEI, J. *et al.* **Chain-of-Thought Prompting Elicits Reasoning in Large Language Models**. 2023. Disponível em: https://arxiv.org/abs/2201.11903.

WU, W. *et al.* **Mind's Eye of LLMs: Visualization-of-Thought Elicits Spatial Reasoning in Large Language Models**. 2024. Disponível em: https://arxiv.org/abs/2404.03622.

WU, X. *et al.* **Usable XAI: 10 Strategies Towards Exploiting Explainability in the LLM Era**. 2025. Disponível em: https://arxiv.org/abs/2403.08946.

YENDURI, G. *et al.* **Generative Pre-trained Transformer: A Comprehensive Review on Enabling Technologies, Potential Applications, Emerging Challenges, and Future Directions**. 2023. Disponível em: https://arxiv.org/abs/2305.10435.

ZHANG, S. *et al.* **Instruction Tuning for Large Language Models: A Survey**. 2024. Disponível em: https://arxiv.org/abs/2308.10792.

ZHANG, W. *et al.* **The Point, the Vision and the Text: Does Point Cloud Boost Spatial Reasoning of Large Language Models?** 2025. Disponível em: https://arxiv.org/abs/2504.04540.

ZHAO, H. *et al.* **Explainability for Large Language Models: A Survey**. 2023. Disponível em: https://arxiv.org/abs/2309.01029.

ZHOU, Y. *et al.* **Navigating the Shortcut Maze: A Comprehensive Analysis of Shortcut Learning in Text Classification by Language Models**. 2024. Disponível em: https://arxiv.org/abs/2409.17455.